Repaso de redes neuronales artificiales

Métodos Generativos, curso 2025-2026

Guillermo Iglesias, guillermo.iglesias@upm.es
Jorge Dueñas Lerín, jorge.duenas.lerin@upm.es
Edgar Talavera Muñoz, e.talavera@upm.es

7 de octubre de 2025

Escuela Técnica Superior de Ingeniería de Sistemas Informáticos | UPM

Repaso de conceptos básicos de redes neuronales

Redes neuronales: concepto general

Una red neuronal es un sistema matemático capaz de aprender ha realizar predicciones a partir de unos datos de entrada, fue propuesta por McCulloch y Pitts en 1943[1], se basaba en imitar el comportamiento de una neurona biológica.

- Toma ciertos estímulos de entrada, los procesa y genera una nueva salida.
- En el caso biológico los estímulos provienen de impulsos nerviosos, mientras que en el caso de las neuronas artificiales esto es replicado a través de cálculos matemáticos.

Neurona biológica

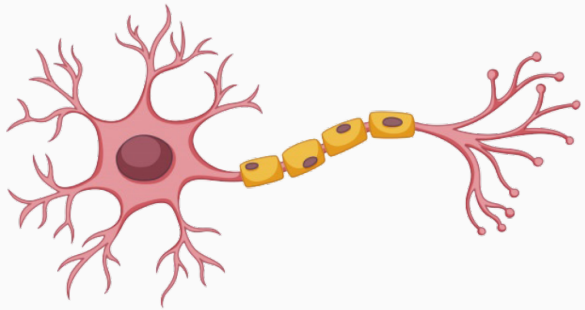

Neurona artificial

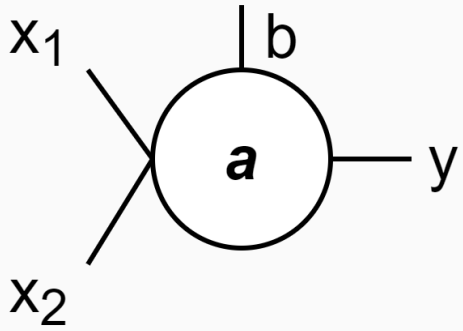

Grandes hitos en redes neuronales

Las redes neuronales han evolucionado a través de hitos clave que han marcado su desarrollo:

- 1943: Neurona artificial (McCulloch y Pitts): Primer modelo matemático inspirado en la biología
- 1958: Perceptrón (Rosenblatt): Uso de funciones de activación como el umbral
- 1986: Retropropagación (Rumelhart et al.): Entrenamiento efectivo de redes profundas
- 1989: CNNs (LeCun et al.): Redes convolucionales para visión por computador
- Inviernos de la IA: Estancamiento. Límites técnicos/expectativas no cumplidas
- 2012: AlexNet: **GPUs** y big data impulsan el aprendizaje profundo moderno
- 2017: Transformers (Vaswani et al.): Nueva arquitectura para NLP.
- 2020s: Difusión: Modelos generativos para imágenes y datos sintéticos
- Actualidad: Grandes modelo multimodales
- Futuro: ¿Invierno o Inteligencia artificial general?

Redes neuronales: concepto general

Una neurona artificial realiza cálculos matemáticos para transformar ciertos valores numéricos. Para dicha labor, existen diversos elementos dentro de una neurona artificial:

- Entradas (x_i): Introducen valores numéricos en la neurona
- Salida (y): Suministra la salida de la neurona
- Pesos (w_i): Son parámetros capaces de cambiar, realizan el aprendizaje de la neurona
- Bias (b): Realiza la misma función que cualquier otro peso, pero el valor de su entrada es siempre 1
- Función de activación (a): Es una función que participa en el cálculo de la salida de la neurona

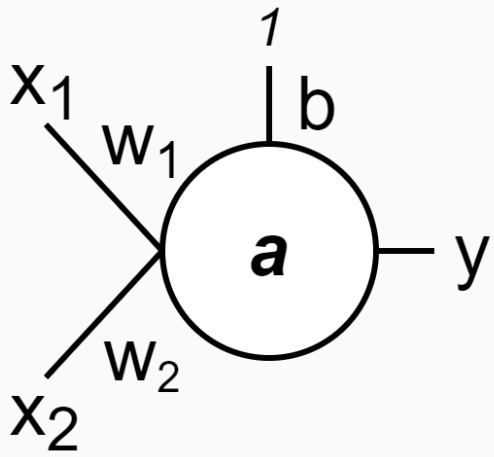

Redes neuronales: bias

El bias (sesgo en Español) permite que la red neuronal pueda ajustar mejor sus predicciones.

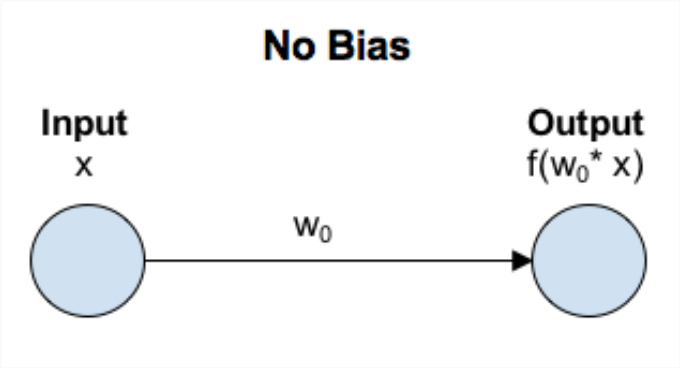

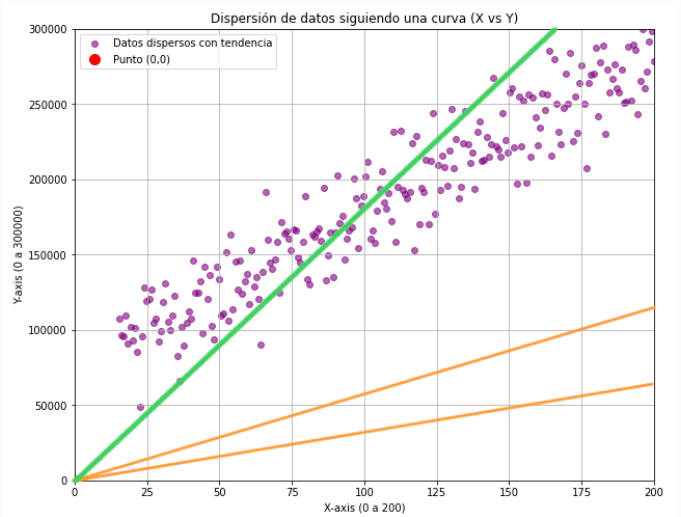

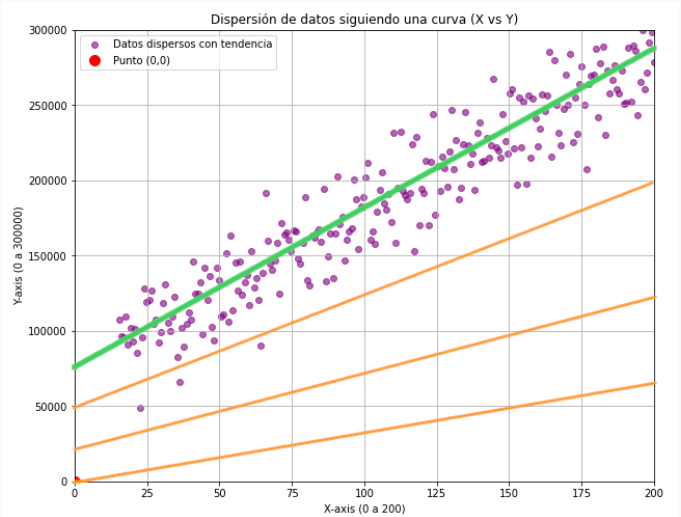

Fuente izq: https://www.pico.net/kb/the-role-of-bias-in-neural-networks/

Redes neuronales: activación

Capas de activación. En salida.

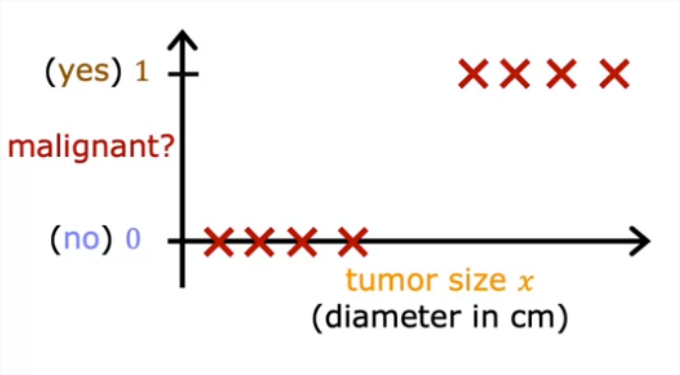

Fuente Coursera

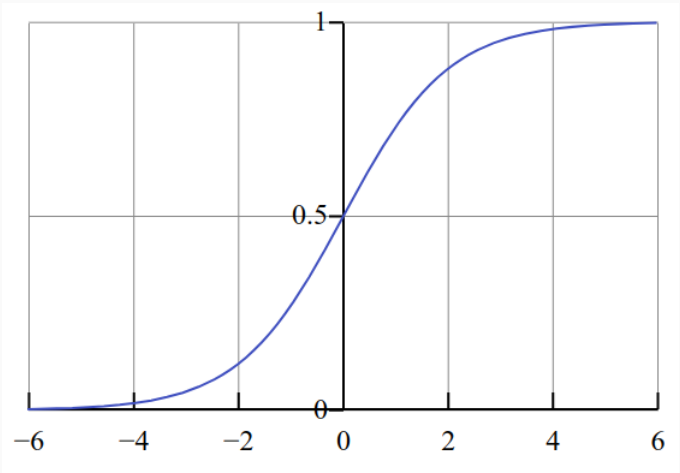

Wikipedia

Sigmoid

$$y = \frac{1}{1 + e^{-z}} \qquad (1)$$

Ejemplo

$$y = \frac{1}{1 + e^{-(3*x-2)}} \qquad (2)$$

Calculadora gráfica

Redes neuronales: activación

Capas de activación. No linealidad.

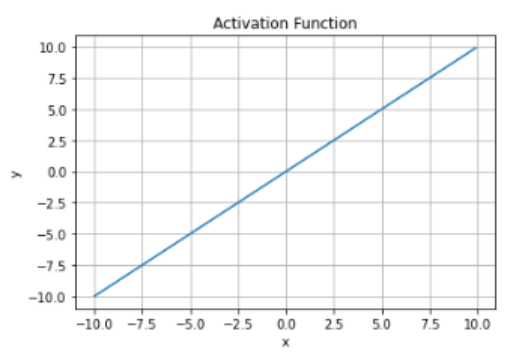

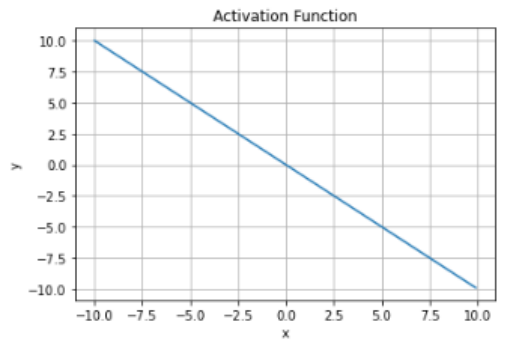

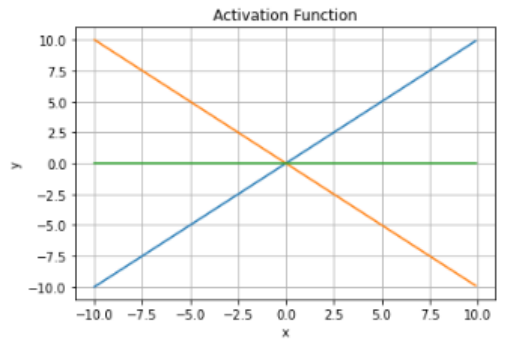

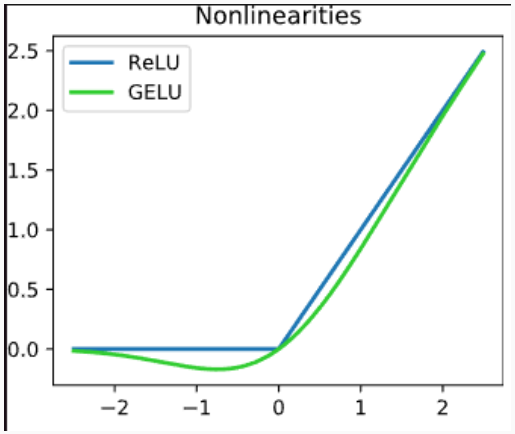

Wikipedia

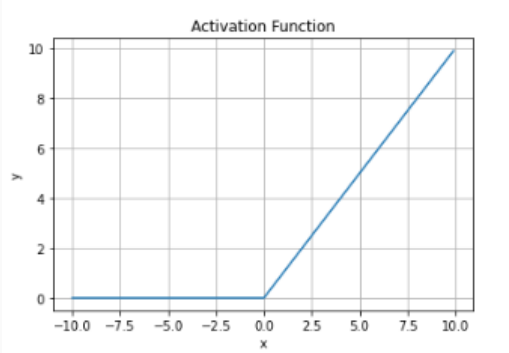

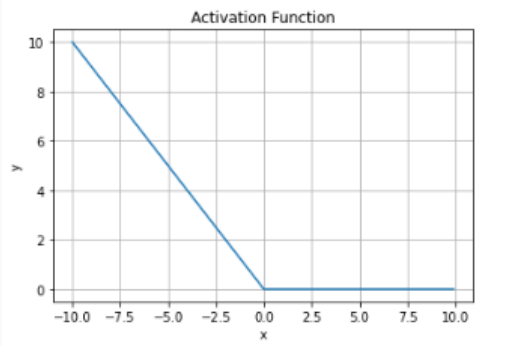

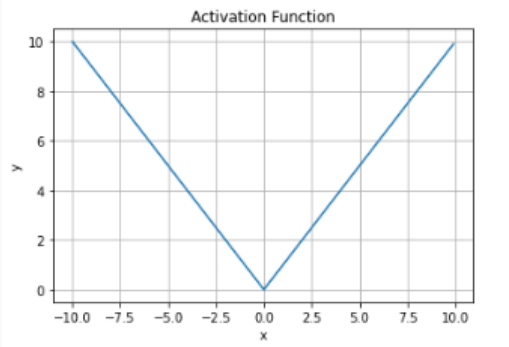

Redes neuronales: activación

Capas de activación. No linealidad. 3D

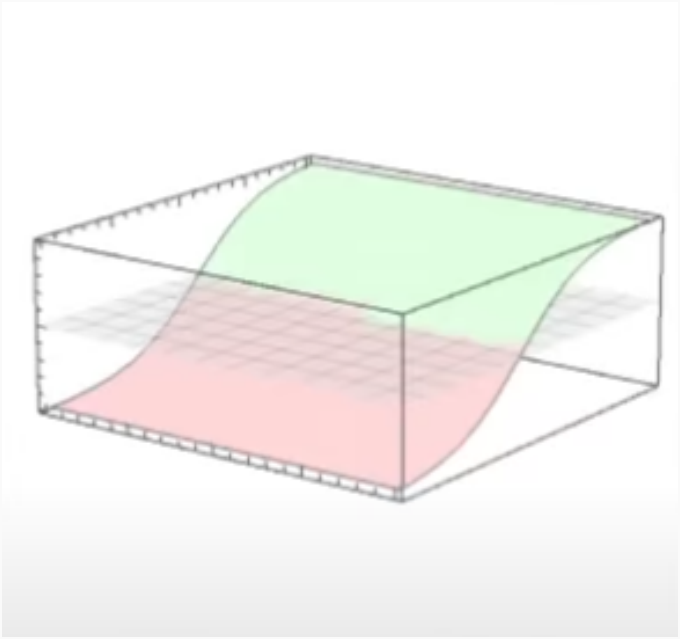

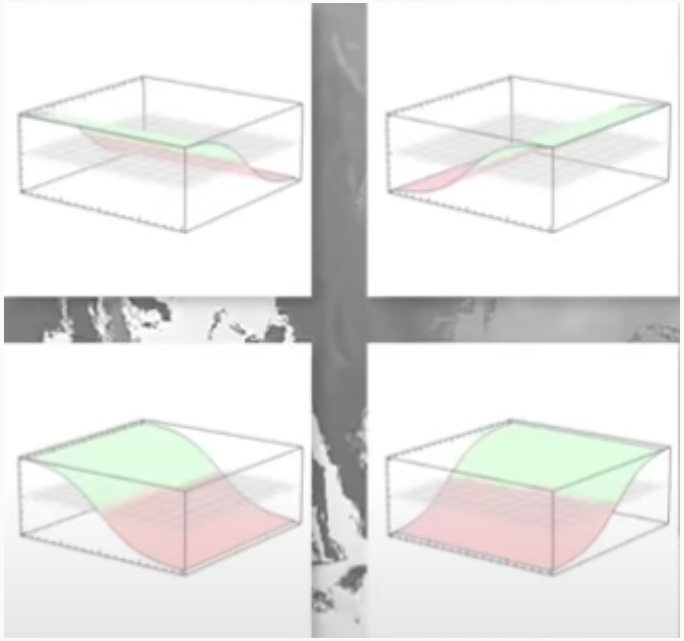

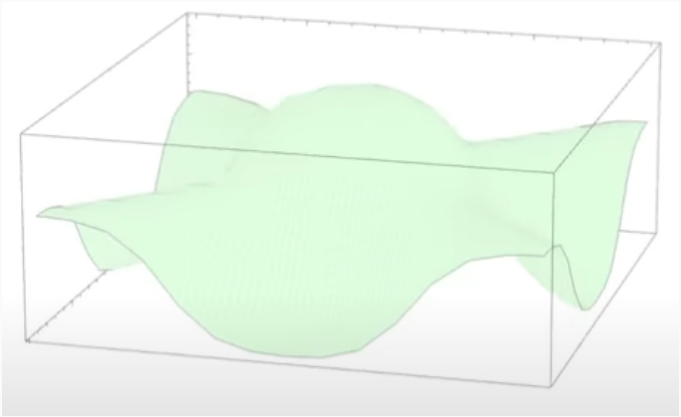

DotCSV

Redes neuronales: entrenamiento

El entrenamiento de las redes neuronales se puede dividir en tres fases:

- Predicción: calculamos para las entradas la predicción de valor de salida de la red.
- Calculo de error: con la predicción y el resultado que queremos obtener calculamos el error obtenido.
- Ajuste de pesos: con el error se reajustan los parámetros de la red.

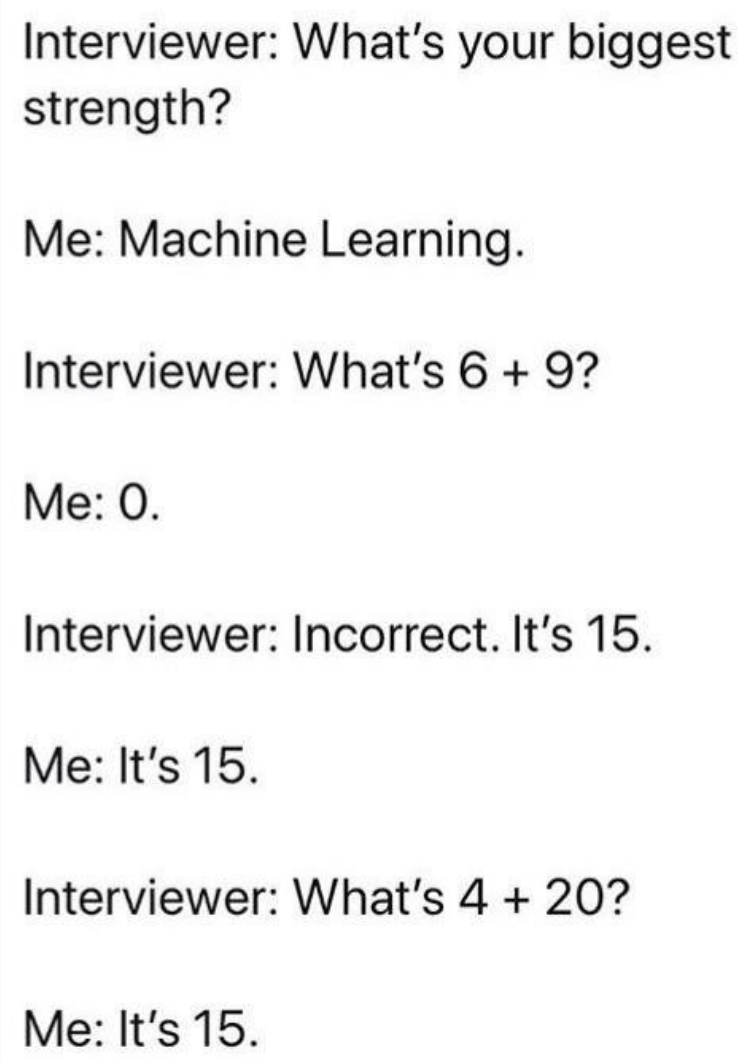

Algoritmo de propagación

La fase de predicción de una red neuronal se realiza a través del algoritmo de propagación.

Este se encarga de procesar la entrada y generar la salida correspondiente.

Para ello, la computación de cada neurona es la siguiente:

- Cada entrada x_i es multiplicada por el valor de su peso correspondiente w_i.
- La entrada de *bias* siempre es "1", y se multiplica por su peso correspondiente (a veces indicado como w_0).
- Todas las entradas de la neurona se combinan haciendo una suma de todas ellas, de tal manera que se realiza una combinación lineal.
- El resultado de la combinación lineal se pasa por una función no lineal para generar la salida de la neurona.

Algoritmo de propagación

La ecuación que define este proceso es la siguiente:

$$f\left(\sum_{i=0}^{n} W_i X_i\right) \tag{1}$$

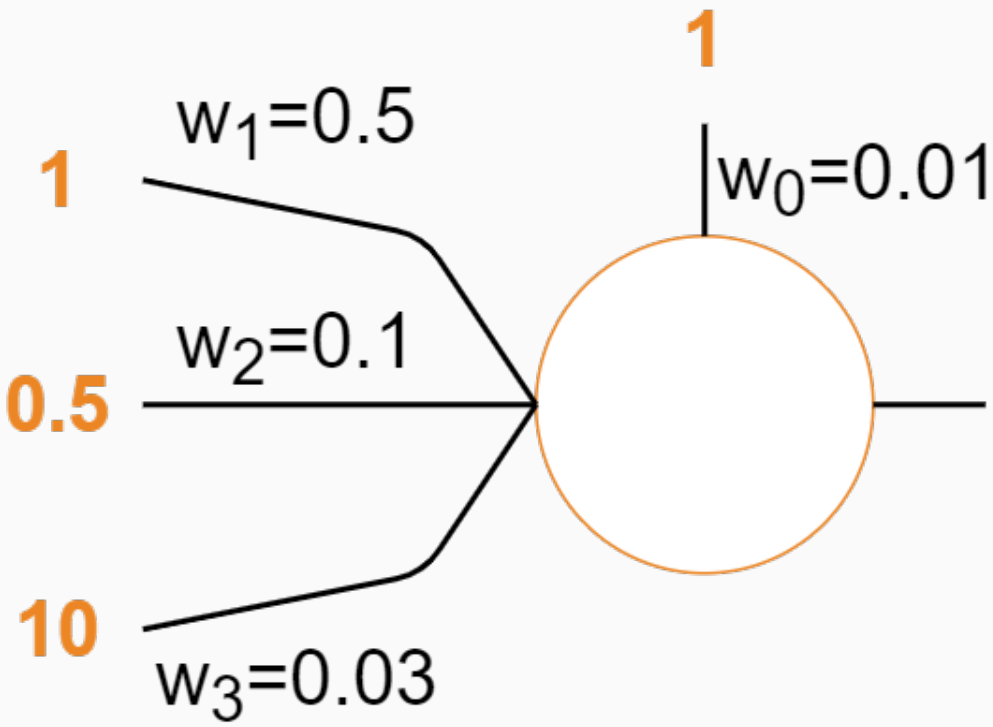

Algoritmo de propagación

La ecuación que define este proceso es la siguiente:

$$f\left(\sum_{i=0}^{n} W_i X_i\right) \tag{1}$$

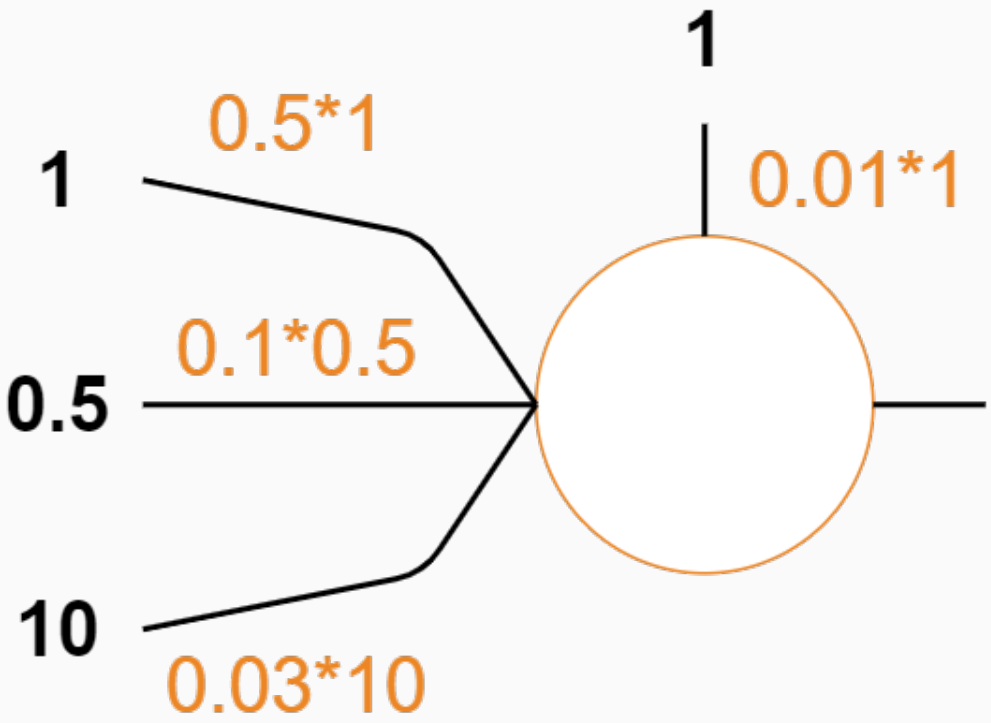

Algoritmo de propagación

La ecuación que define este proceso es la siguiente:

$$f\left(\sum_{i=0}^{n} W_i X_i\right) \tag{1}$$

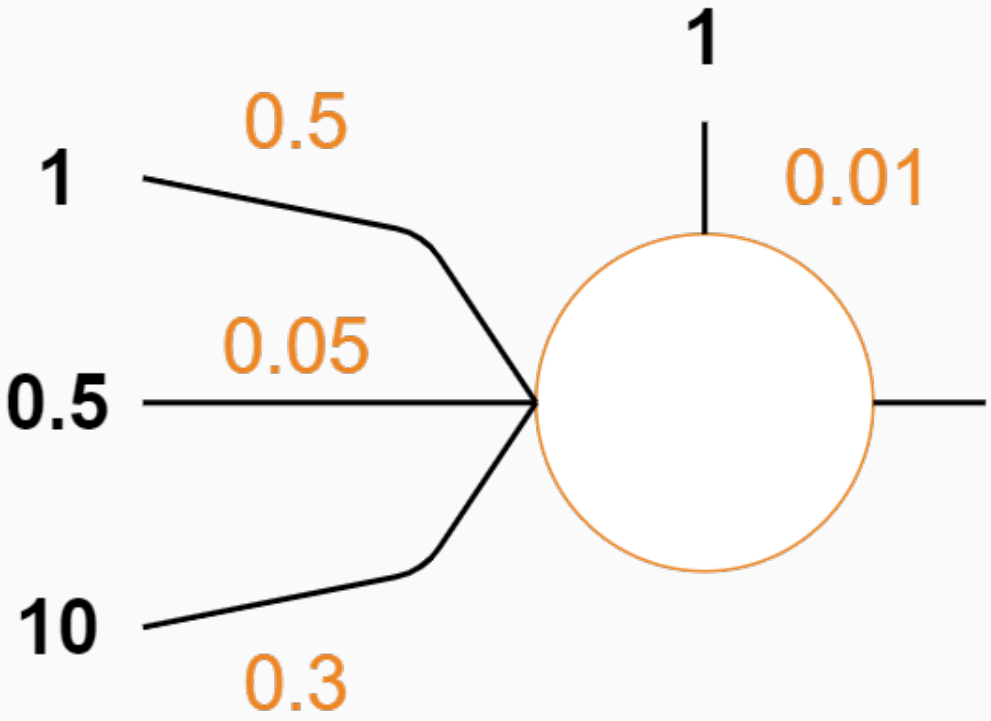

Algoritmo de propagación

La ecuación que define este proceso es la siguiente:

$$f\left(\sum_{i=0}^{n} W_i X_i\right) \tag{1}$$

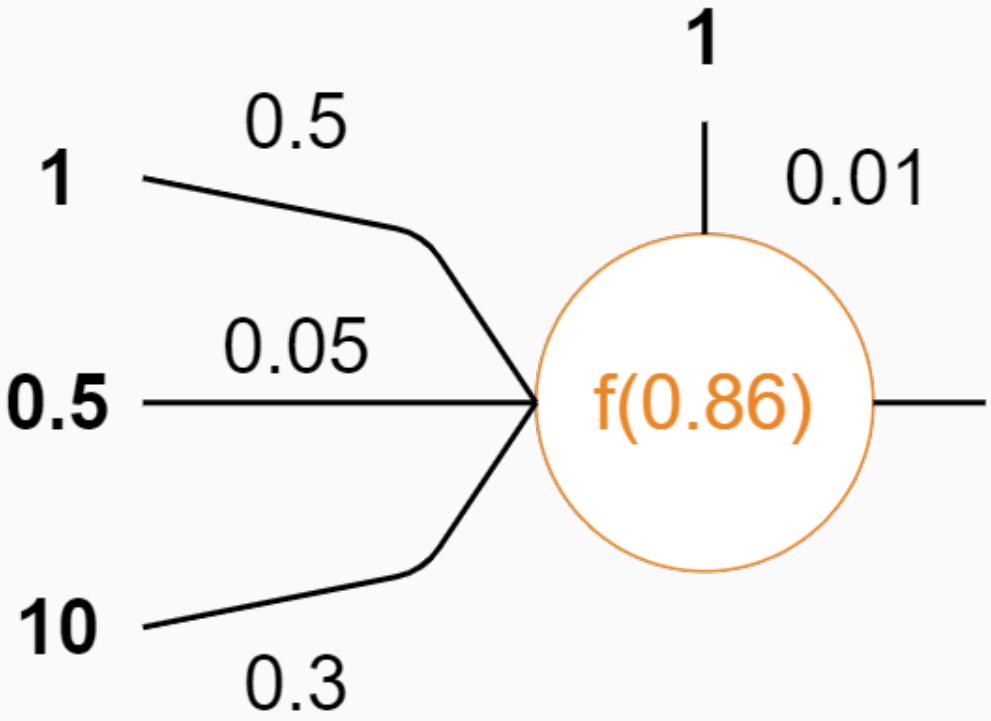

Algoritmo de propagación

La ecuación que define este proceso es la siguiente:

$$f\left(\sum_{i=0}^{n} W_i X_i\right) \tag{1}$$

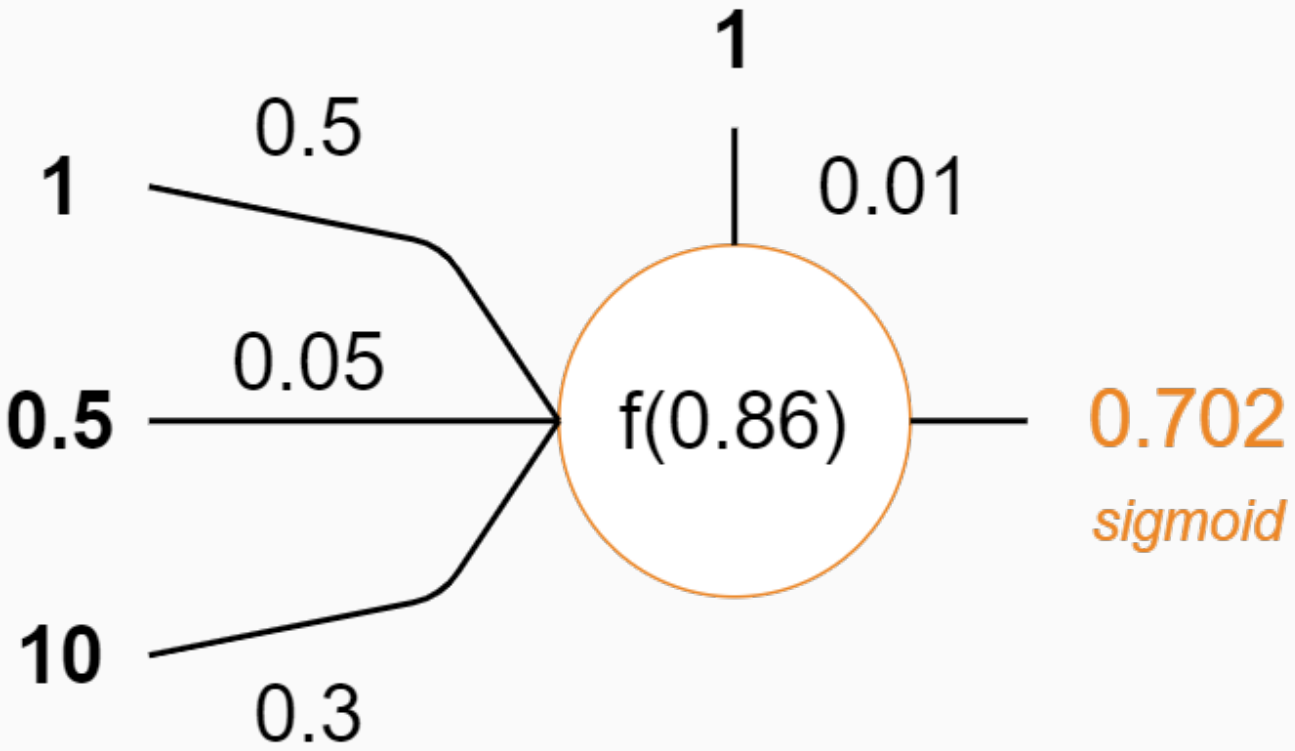

Funciones de activación

Las funciones de activación de cada neurona pueden variar, entre las más populares se encuentran:

Activation Functions

Sigmoid

$$\sigma(x) = \frac{1}{1+e^{-x}}$$

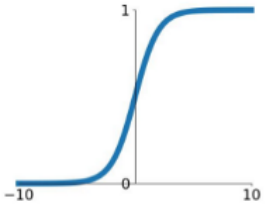

Leaky ReLU

$$\max(0.1x, x)$$

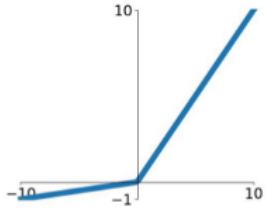

tanh

$$\tanh(x)$$

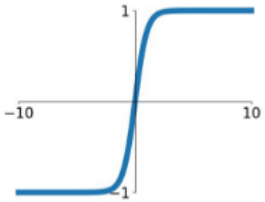

Maxout

$$\max(w_1^T x + b_1, w_2^T x + b_2)$$

ReLU

$$\max(0, x)$$

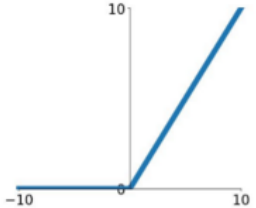

ELU

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$

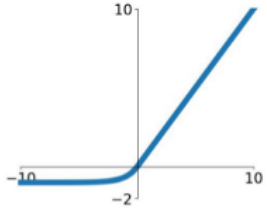

[2]

Estructura de capas

Una red de neuronas “estándar” se organiza por capas, las cuales se componen por varias neuronas.

Cada capa de neuronas se conecta con la siguiente y recibe datos de la anterior. De esta manera se produce el flujo de datos a lo largo de la red.

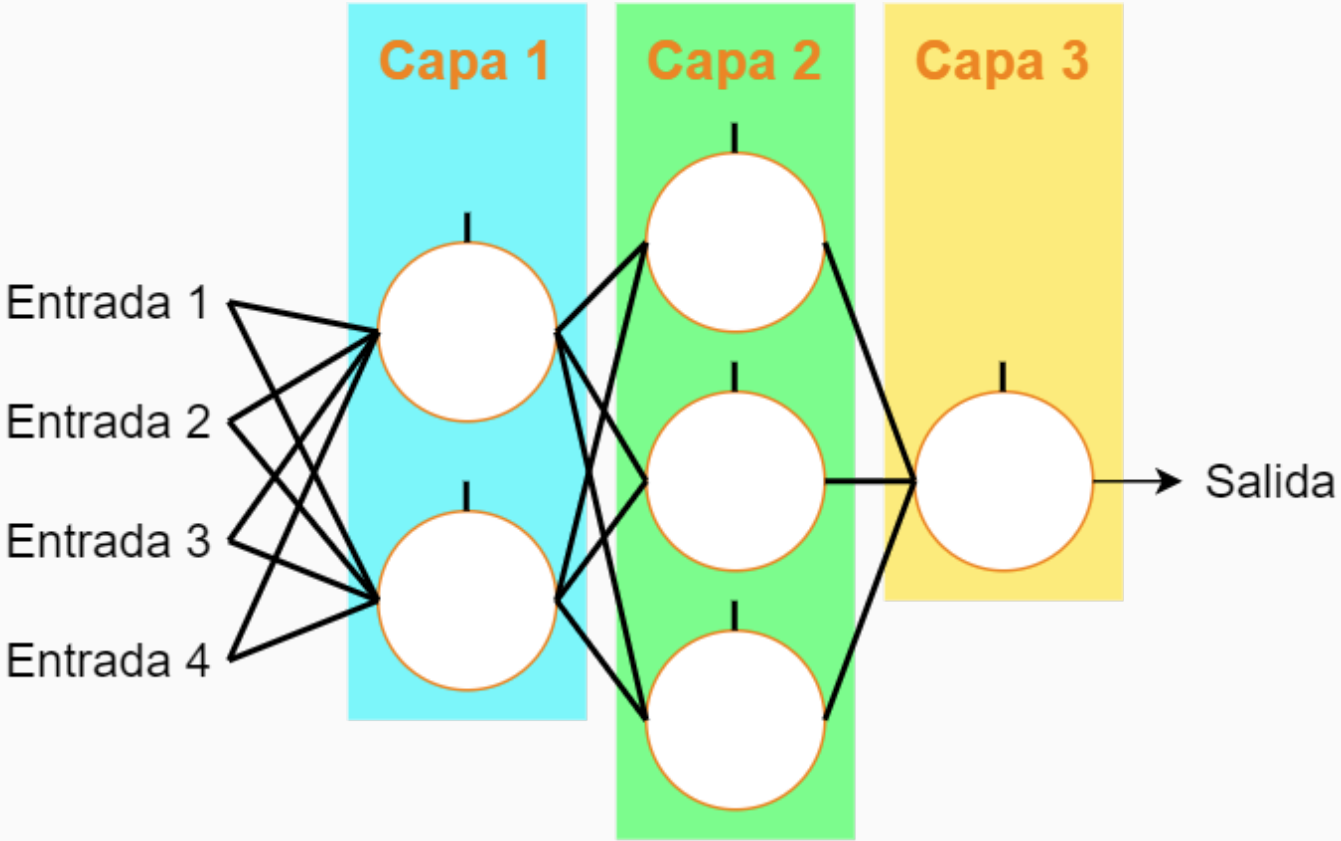

¿Por qué introducir más capas?

Está matemáticamente demostrado que sin función de activación las redes de neuronas sólo son capaces de resolver problemas linealmente separables.

Esto es fácilmente demostrable, ya la computación de cada neurona corresponde con la ecuación de una recta, y su combinación también.

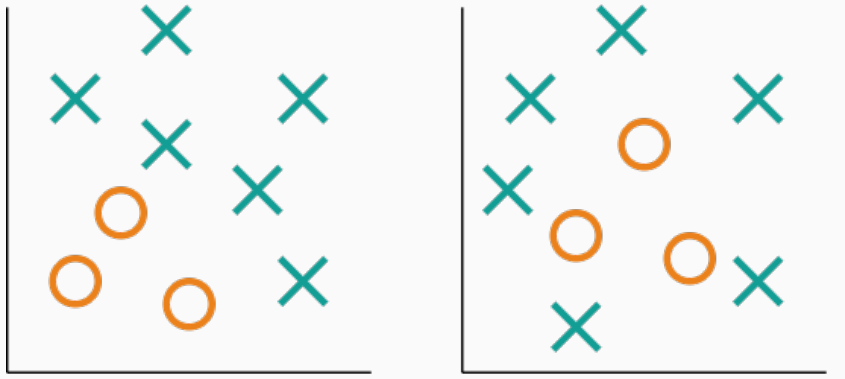

Por otra parte, K. Hornik, M. Stinchcombe, y H. White demostraron el 1985 que con una única capa oculta las redes neuronales artificiales se convierten en aproximadores universales [3].

Gradient descent y learning rate

Descenso de gradiente: algoritmo de optimización iterativo de primer orden que permite encontrar mínimos locales en una función diferenciable. (Wikipedia).

¿Cómo funciona? Derivadas parciales para bajar la pendiente.

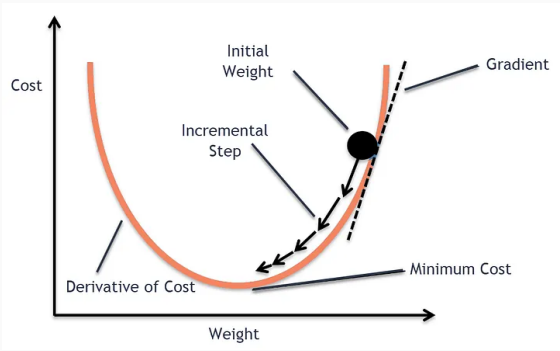

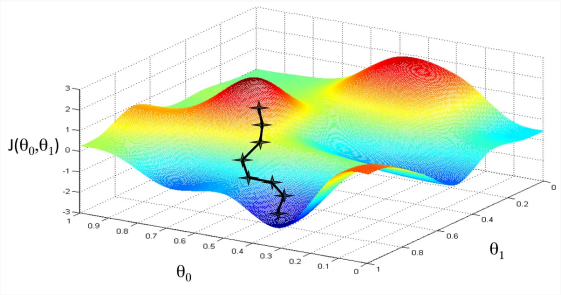

¡Ojo! pérdida no datos

Gradient descent un parámetro (learning rate)

Gradient descent w y b(batch size) y Optimizadores

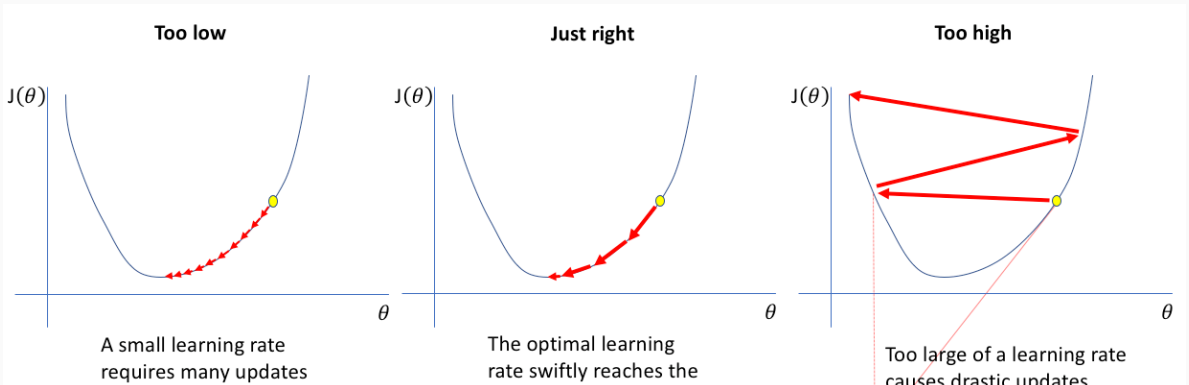

Algoritmo de retropropagación

El algoritmo de retropropagación o backpropagation es el encargado de adaptar la red de neuronas a su cometido específico.

Se basa en actualizar los pesos de la red dependiendo del error que esta haya tenido a la hora de predecir una salida en concreto.

Con backpropagation obtendremos los gradientes (derivadas) de la función de pérdida para cada peso de cada capa oculta.

$$\triangle w_i = w_i - \alpha \cdot (Error) \tag{2}$$

donde α es el learning rate, que define la magnitud con la que la red realiza la actualización de sus pesos.

Backpropagation interactivo

Funciones de pérdida

Existen múltiples métodos para calcular la distancia de la predicción $\hat{y}$ con respecto de la salida deseada y. Es decir, múltiples funciones de pérdida que nos permiten calcular el error.

$$\text{MAE} = \frac{1}{n}\sum |y - \hat{y}| \tag{3}$$

$$\text{MSE} = \frac{1}{n}\sum (y - \hat{y})^2 \tag{4}$$

$$\text{Binary Cross-Entropy} = -\left(y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})\right) \tag{5}$$

Dibujo de la funciónlog. Condicional if -> $y * \ldots + (1 - y) * \ldots$

$$\text{Cross-Entropy} = -\sum_{i=1}^{N} y \cdot \log \hat{y} \tag{6}$$

Entrenamiento de redes neuronales

Al realizar un entrenamiento con modelos de aprendizaje se realiza una división del conjunto de datos con el que se entrena. Este proceso ayuda a comprobar la fiabilidad de la red.

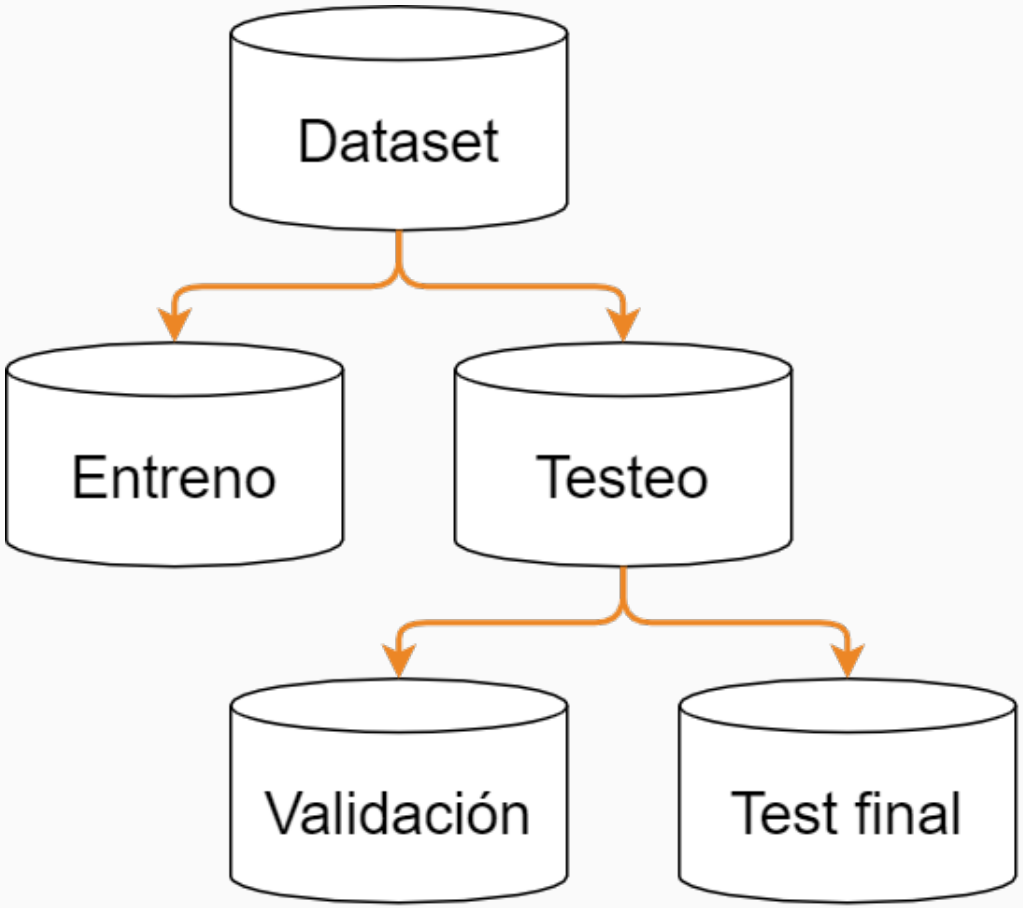

Playground

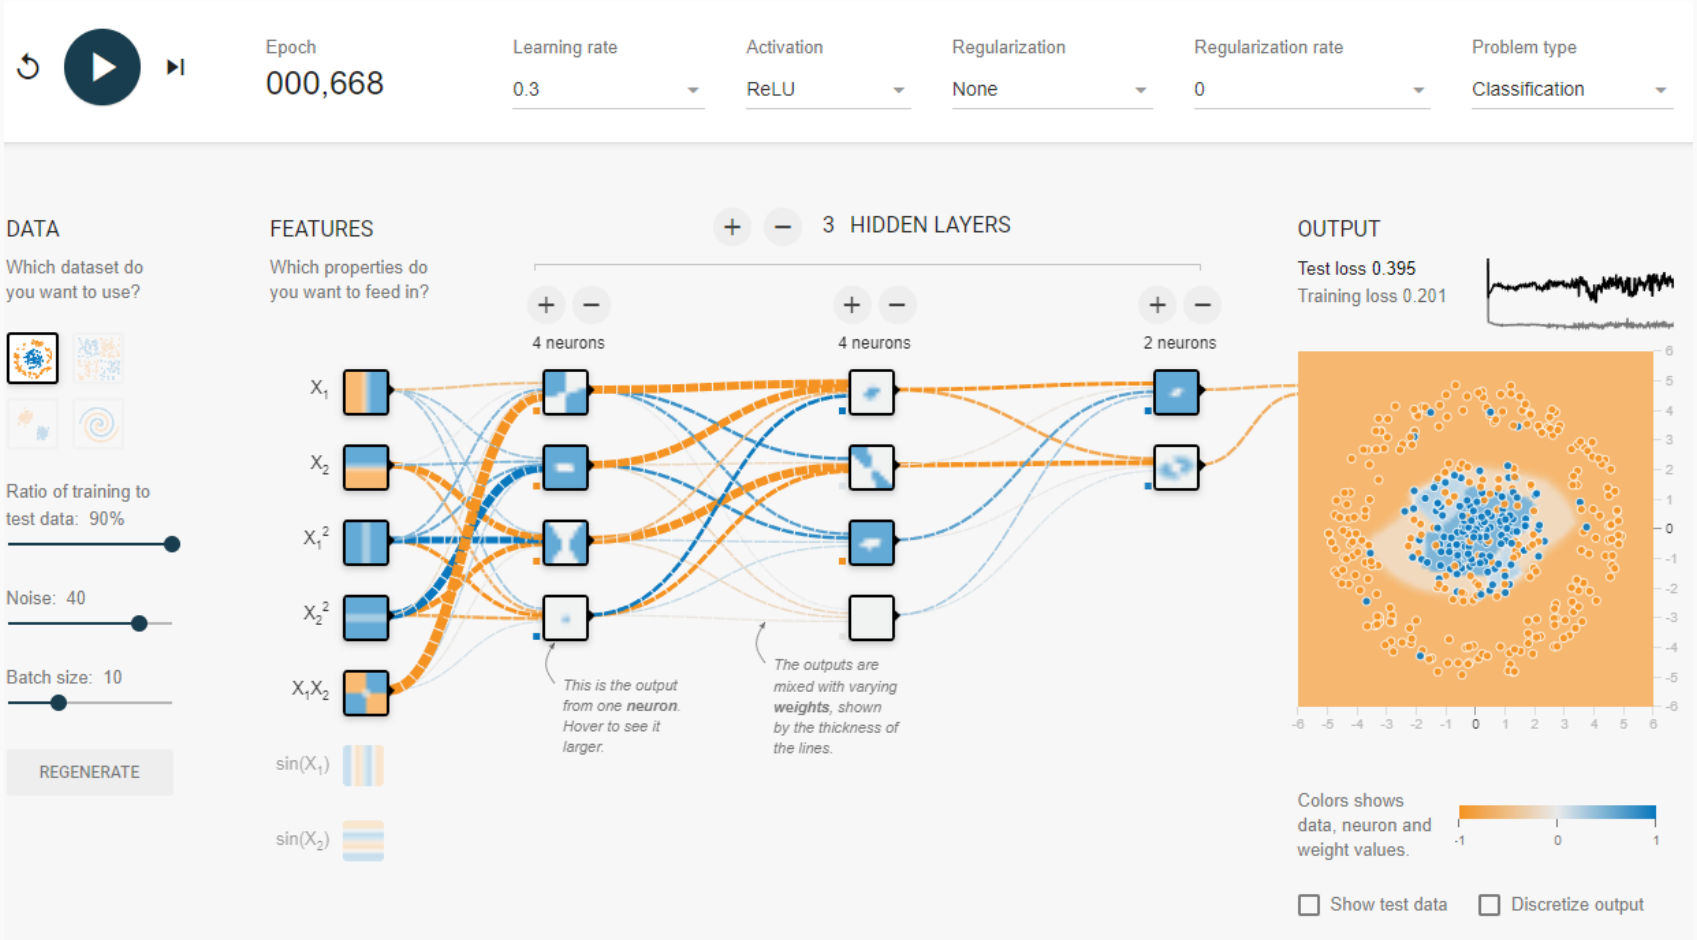

Tensorflow playground

Ejercicios 1 y 2 completo. Ejercicio 3 introducción a siguientes conceptos.

Bias-variance tradeoff

Existen dos conceptos fundamentales que ayudan a analizar el rendimiento de una red neuronal:

- Bias (sesgo): Error sistemático que aparece cuando el modelo es demasiado simple para capturar la complejidad de los datos. Se manifiesta en un alto error incluso en el conjunto de entrenamiento.
- Variance (varianza): Error debido a la excesiva sensibilidad del modelo a los datos de entrenamiento. Se observa cuando existe una gran diferencia entre el error en entrenamiento y el error en test.

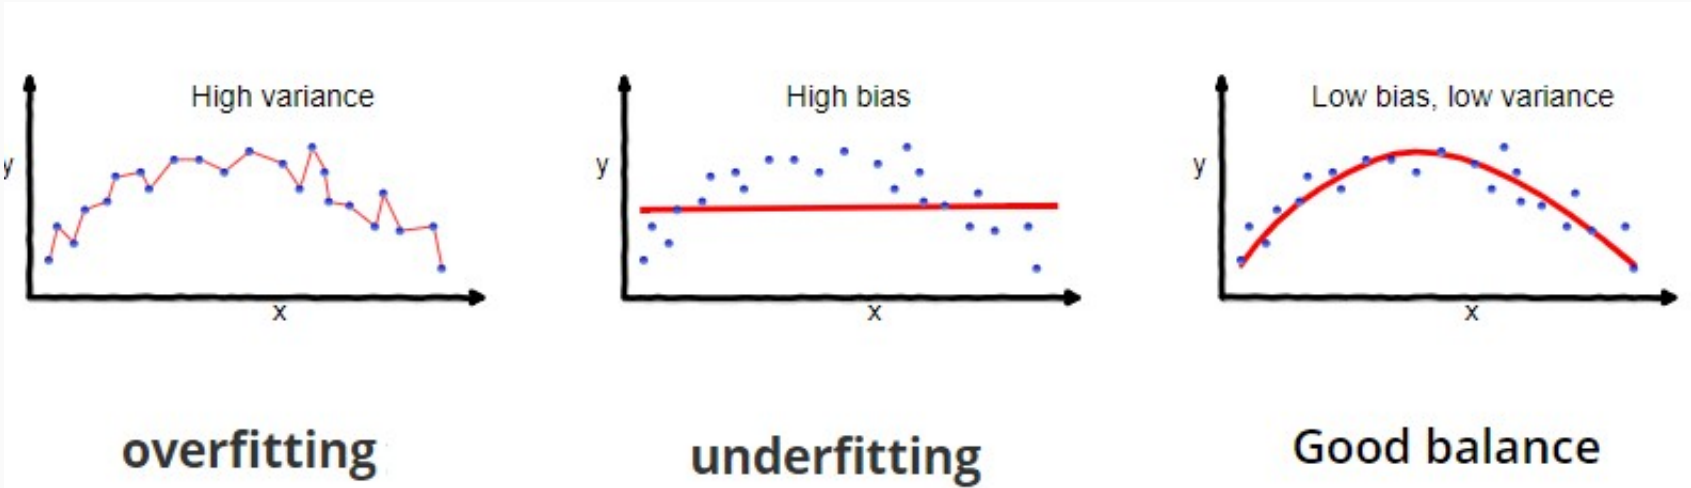

Bias-variance tradeoff

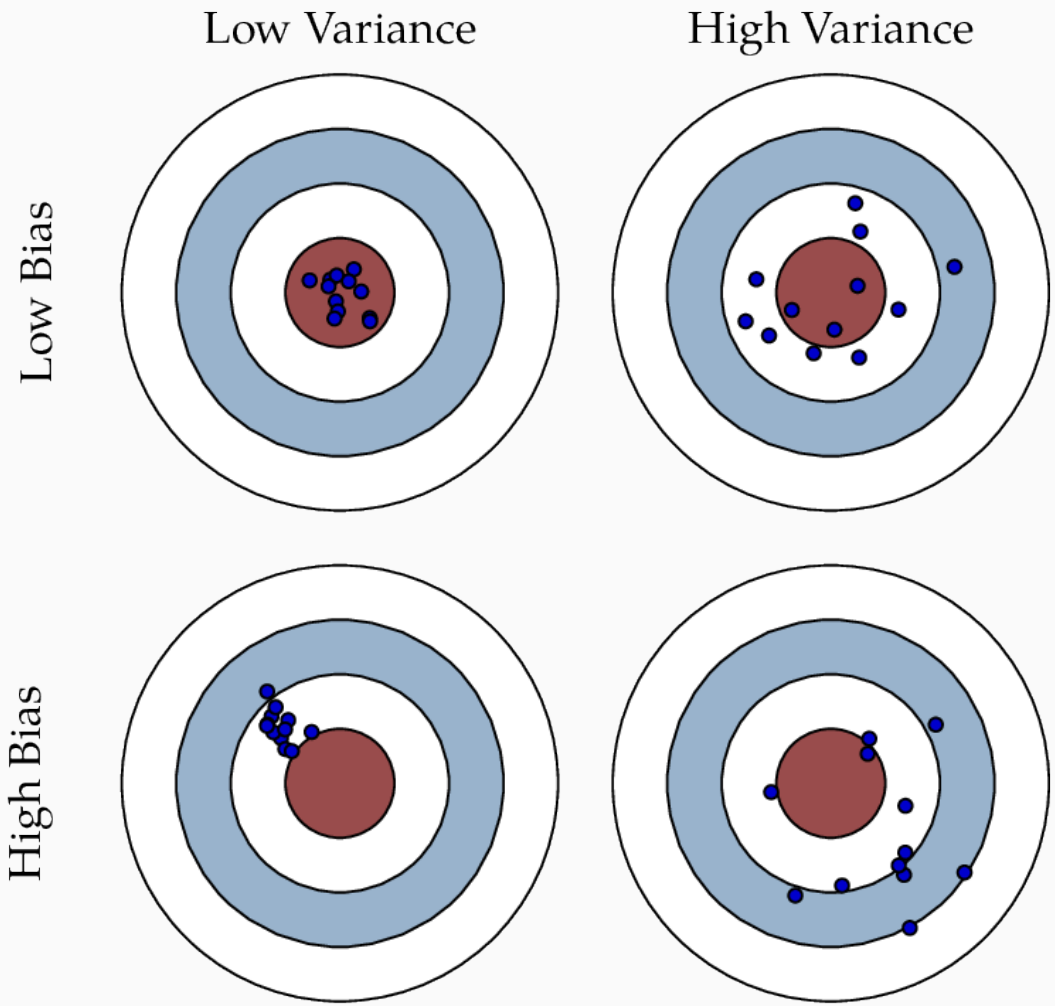

[5]

¿Cómo detectar alto bias o variance?

Alto bias

- Underfitting.
- Sobre-simplificación del problema.
- Valores de pérdida demasiado altos.
- Falla al capturar la tendencia de los datos.

Alto variance

- Overfitting.
- Dataset demasiado ruidoso.
- Demasiada complejidad.

Esquema general de entrenamiento de redes neuronales

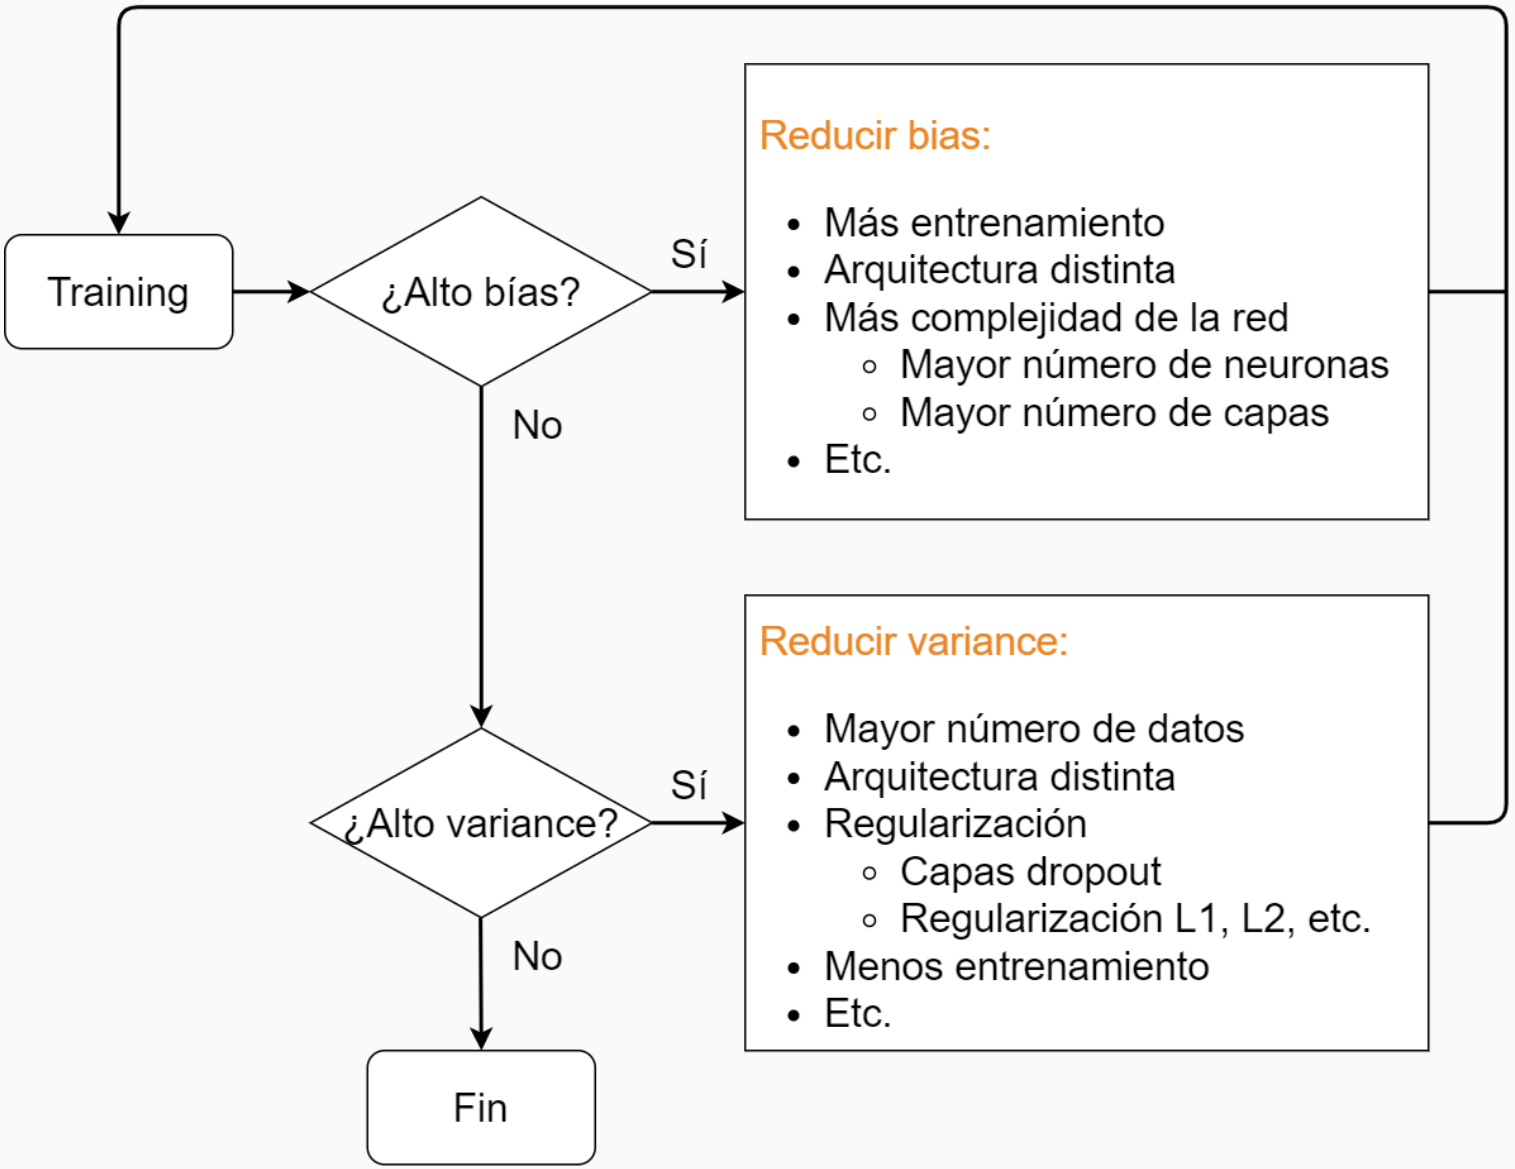

Problemas del gradiente

Los problemas derivados del gradiente son comunes a todas las redes neuronales. Estos están directamente influenciados por el número de capas de la red.

Se diferencian dos tipos:

- Gradient explosion.
- Gradient vanishing.

Al realizarse la retropropagación los valores de pérdida pasan de unas capas a otras. En este algoritmo las derivadas de cada neurona pueden llegar a descontrolarse.

$$W'_x = W_x - \alpha \left(\frac{\partial \text{Loss}}{\partial W_x} \right) \tag{7}$$

Problemas del gradiente: Gradient explosion

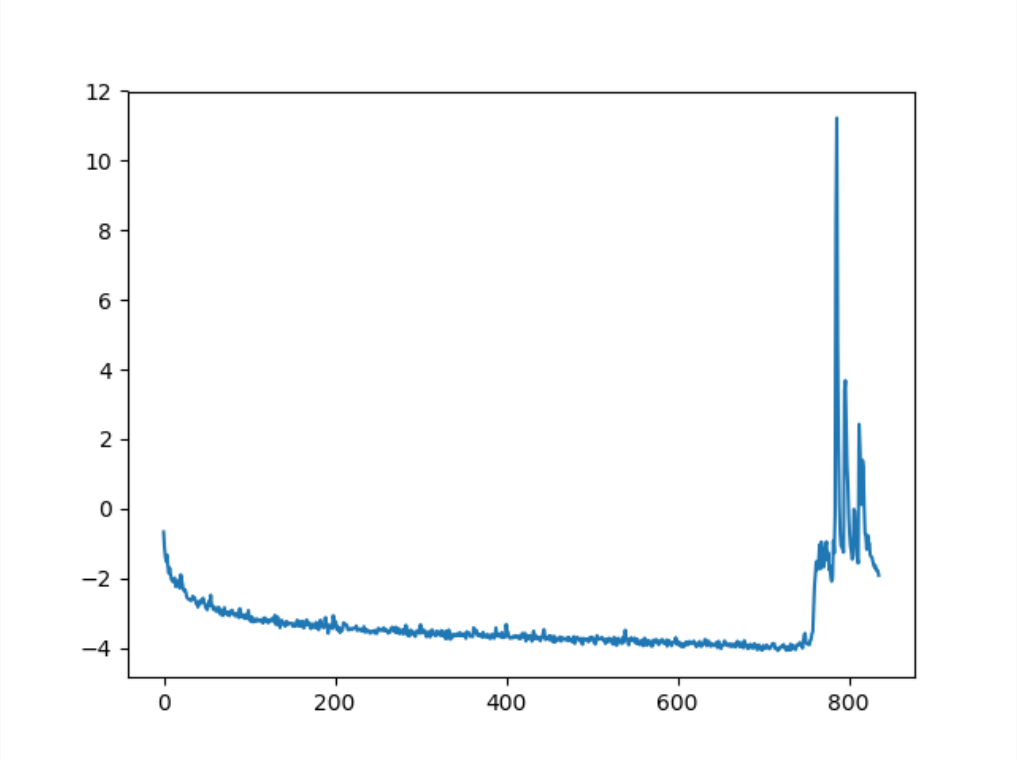

[6]

El gradient explosion, también conocido como exploding gradients sucede cuando la actualización de pesos toma valores muy elevados.

Se identifica con valores de pérdidas de NaN o muy exageradas.

Problemas del gradiente: Gradient Vanishing

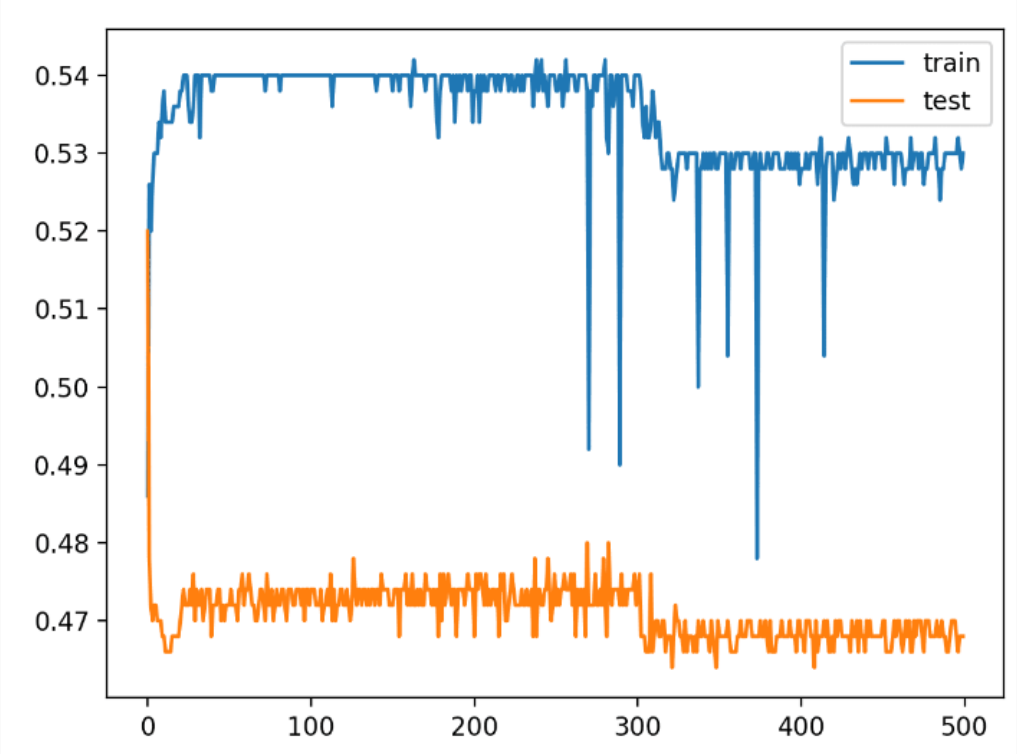

[7]

Cuando sucede gradient vanishing, también llamado vanishing gradients, la actualización de pesos se hace nula por tener valores muy pequeños.

Se identifica cuando la pérdida es constante en el tiempo.

Origen de los problemas derivados del gradiente

La principal causa de estos problemas es usar funciones de activación cuya derivada satura a 0.

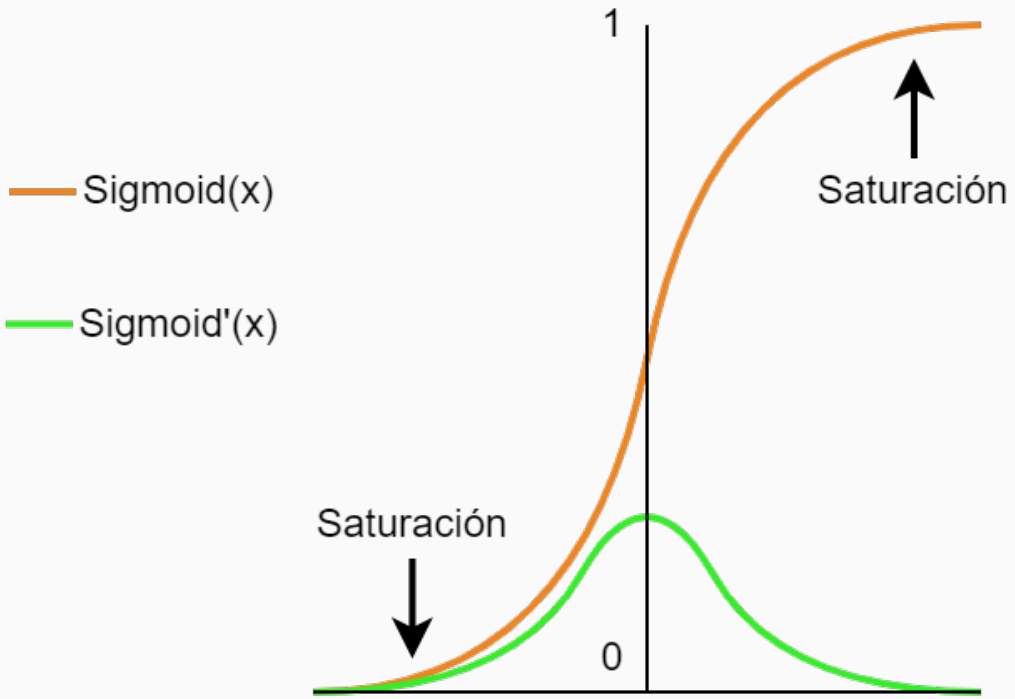

Sucede principalmente con las funciones tanh y sigmoid, por lo tanto se recomienda el uso de ReLU para capas ocultas en una red.

Notebook de ejemplo, perceptrón clasificador

El siguiente notebook contiene un ejemplo de clasificador usando un perceptrón multicapa como red neuronal.

- 1.1_1-PerceptronClasificador.ipynb

Perceptrón multicapa para procesar imágenes

¿Cómo procesar imágenes?

La idea más básica para procesar imágenes con redes neuronales es transformar la matriz numérica de datos a un vector unidimensional.

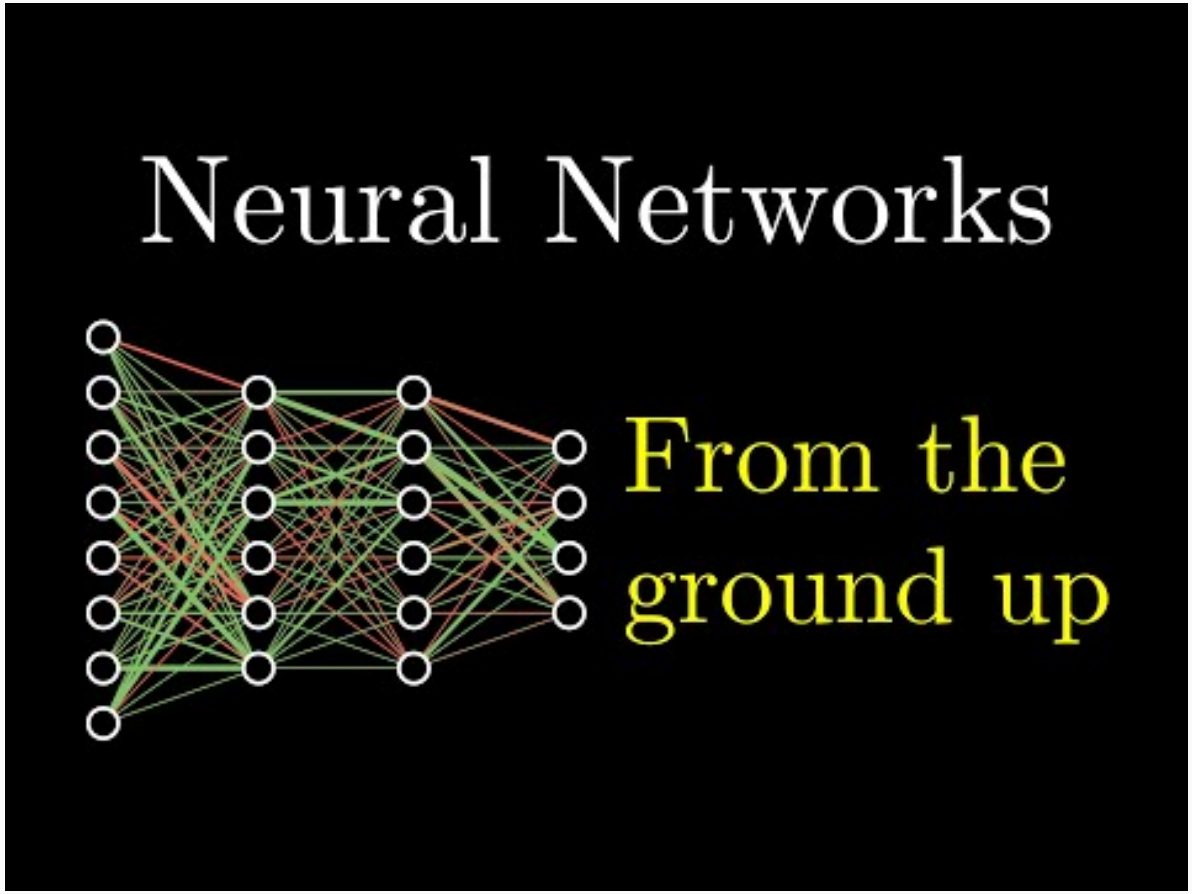

Vídeo youtube

Capa de reshape

La capa de keras llamada “reshape” se encarga de realizar transformaciones en los tensores. Ya que solo queremos convertir la imagen en un vector “plano”, también podemos utilizar la capa “flatten” de matriz a vector.

Sin embargo el principal inconveniente al tratar las imágenes de esta manera es la pérdida total de información espacial de la imagen.

Notebook de ejemplo, perceptrón clasificador de imágenes

El siguiente notebook contiene un código parcial de clasificador de imágenes usando un perceptrón multicapa como red neuronal.

- 1.1_2-PerceptronImagenes.ipynb

Si quieres usar estas redes sencillas en otros datasets puede probar con Wine dataset y con Fashion MNIST.

Referencias i

[1] Warren S McCulloch and Walter Pitts.
A logical calculus of the ideas immanent in nervous activity.
The bulletin of mathematical biophysics, 5(4):115–133, 1943.

[2] Data Science Interview Preparation.
Activation functions image.
https://www.datasciencepreparation.com/blog/articles/what-is-an-activation-function-what-are-commonly-used-activation-functions/.
[Online; accessed August, 2022].

[3] Kurt Hornik, Maxwell Stinchcombe, and Halbert White.
Multilayer feedforward networks are universal approximators.
Neural networks, 2(5):359–366, 1989.

Referencias ii

[4] The Machine Learners.
Bias variance tradeoff image.
https://www.themachinelearners.com/tradeoff-bias-variance/.
[Online; accessed August, 2022].

[5] endtoend.ai.
Bias variance tradeoff image.
https://www.endtoend.ai/blog/bias-variance-tradeoff-in-reinforcement-learning/.
[Online; accessed August, 2022].

[6] acrosson (GitHub).
Gradient explosion image.
https://github.com/NVIDIA/waveglow/issues/122.
[Online; accessed August, 2022].

Referencias iii

[7] Jason Brownlee (Machine Learning Mastery).
Gradient vanishing image.
https://machinelearningmastery.com/how-to-fix-vanishing-gradients-using-the-rectified-linear-activation-function/.
[Online; accessed August, 2022].

Contribuciones de las diapositivas

- **Autor original de las diapositivas:** Guillermo Iglesias Hernández
- **Extensión de contenido:** Jorge Dueñas Lerín