Del Transformer Original al Ecosistema Moderno

Métodos Generativos, curso 2025-2026

Guillermo Iglesias, guillermo.iglesias@upm.es
Jorge Dueñas Lerín, jorge.duenas.lerin@upm.es
Edgar Talavera Muñoz, e.talavera@upm.es

5 de noviembre de 2025

Escuela Técnica Superior de Ingeniería de Sistemas Informáticos | UPM

Contenidos

Evolución y Variantes de Transformers

Recap: ¿Por qué funcionó tan bien el transformer original?

- **Atención**: mecanismo que facilita capturar dependencias a largo plazo sin recurrencia
- **Paralelización**: eliminación de dependencias secuenciales
- **Escalabilidad**: arquitectura capaz de aprovechar grandes cantidades de datos
- **Transferibilidad**: representaciones aprendidas útiles para múltiples tareas

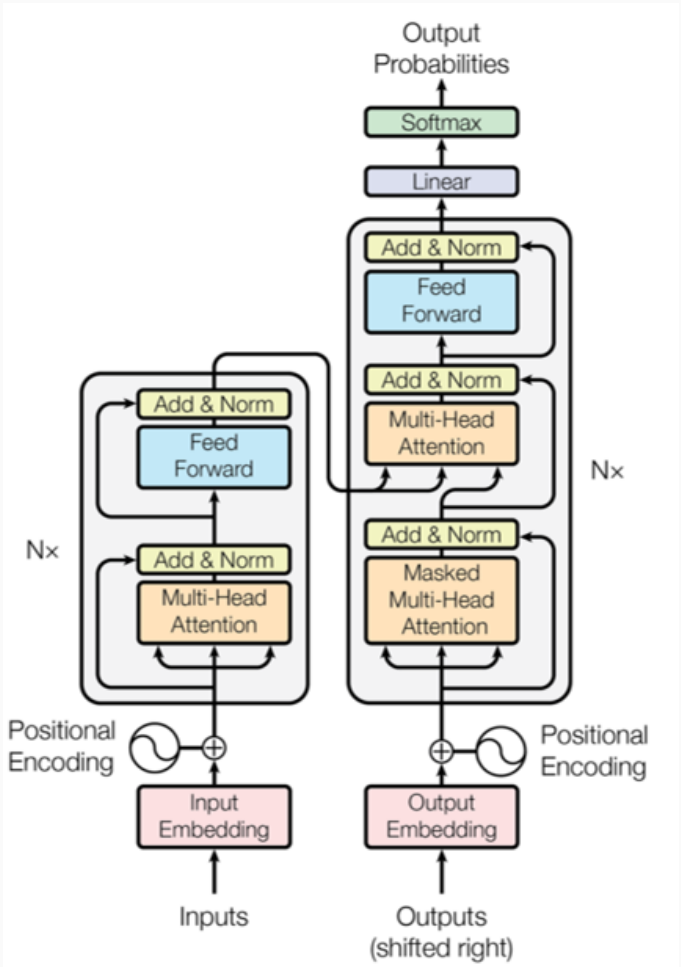

Estos principios han dado lugar a tres familias arquitectónicas principales...

Las tres familias arquitectónicas

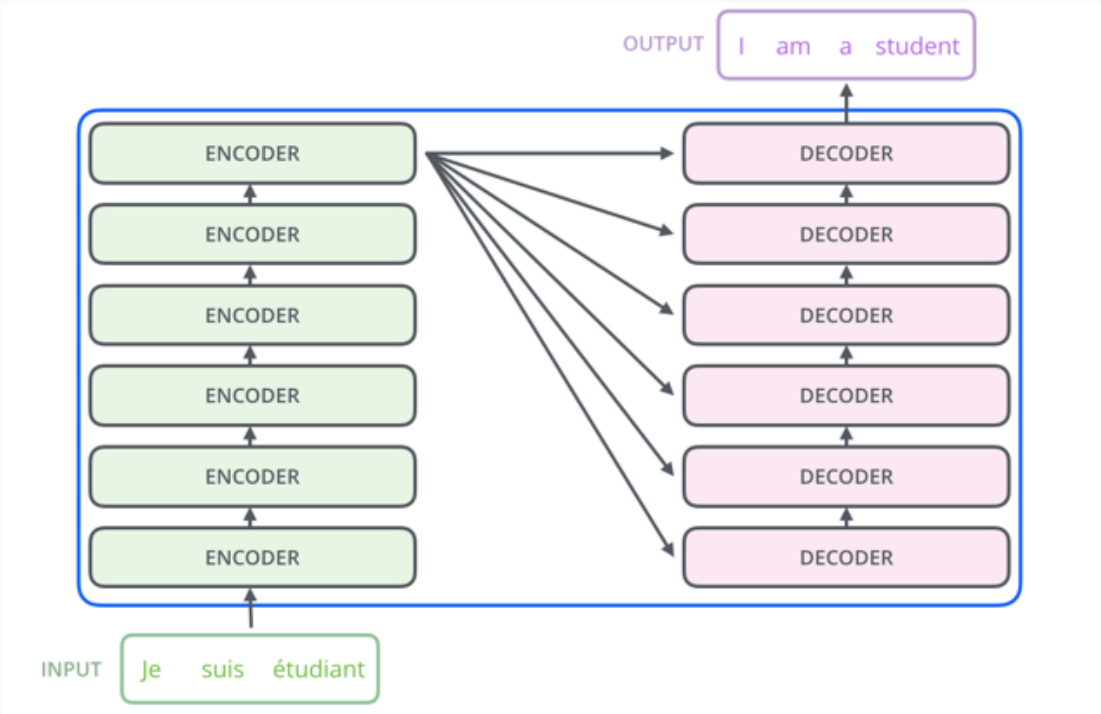

De este diseño original se derivan tres familias: los modelos que entienden (encoder-only), los que generan (decoder-only) y los que traducen de una representación a otra (encoder-decoder).

- **Encoder-only**: solo la parte izquierda (encoders apilados)
- **Decoder-only**: solo la parte derecha (decoders apilados),
  - sin cross-attention pero con masked-attention
- **Encoder-decoder**: la arquitectura completa

Fases entrenamiento, tareas y modelos de ejemplos

Tareas: Upstream vs Downstream

Pretraining (conocimiento general) → **Fine-tuning** (tarea específica)

Upstream Task (Tarea general)

- Objetivo **inicial** del entrenamiento del modelo base
- Grandes volúmenes de datos, principalmente **no etiquetados**
- Aprendizaje **auto-supervisado o con supervisión débil**
- El modelo adquiere patrones lingüísticos y conocimiento general del mundo

Downstream Task (Tarea específica)

- Tarea **final** o aplicación concreta
- Datos más limitados, normalmente **etiquetados**
- Aprendizaje **supervisado o basado en instrucciones**
- El modelo se adapta al dominio o tarea de interés

Tareas: otras estrategias

Continued pretraining / Domain Adaptation

- Corpus de dominio específico sin etiquetar
- Ejemplo: textos médicos, legales, etc.
- Mismo **tipo** de objetivo: aprender más sobre el lenguaje pero con datos especializados
- Adapta vocabulario y conocimiento del dominio

Aprendizaje sobre las tareas en el contexto (In-context learning)

- Grandes modelos del lenguaje
- Grandes ventanas de contexto
- Aprender de la tarea sin modificar pesos.
- Ejemplo: zero-shot, few-shot, etc.

Generación Aumentada por Recuperación (RAG)

- Vectorización de conocimiento
- Inyección en el contexto

Taxonomía de Tareas: Auto-supervisadas (sin etiquetas)

Sin etiquetas específicas:

MLM *Masked Language Modeling*

- Predecir tokens enmascarados usando contexto bidireccional.
- **Ejemplo:** ”El gato está ___ la alfombra” → ”sobre”.

CLM *Causal Language Modeling*

- Predecir el siguiente token (autoregresivo).
- **Ejemplo:** ”El clima está” → ”soleado”.

NSP Next Sentence Prediction — predecir si una oración sigue a otra en el texto original.

- **Ejemplo:**
  - A: ”Juan salió de casa.”
  - B: ”Luego compró pan.”
  - Etiqueta: Verdadero (sí son consecutivas).

Taxonomía de Tareas: Auto-supervisadas (sin etiquetas)

SOP *Sentence Order Prediction*

- Determinar el orden correcto de oraciones.
- **Ejemplo:** ”Juan salió. Luego compró pan.” vs ”Luego compró pan. Juan salió.”

RTD *Replaced Token Detection*

- Detectar tokens falsos (ELECTRA).
- **Ejemplo:** ”El perro comió pizza” → detectar que ”pizza” es improbable.

Span Corruption

- Predecir secuencias enmascaradas.
- **Ejemplo:** ”El ___ está ___ la mesa” → ”libro”, ”sobre”.

Taxonomía de Tareas: Supervisadas (Fine-tuning)

Con etiquetas específicas:

Text Classification Categorizar texto completo.

- **Ejemplo:** ”Este producto es excelente”
- Sentimiento: positivo.

Token Classification Etiquetar cada token.

- **Ejemplo NER:** ”Barack Obama nació en Hawái”
- [Persona: Barack Obama], [Lugar: Hawái].
- **Ejemplo POS**: Part-of-Speech tagging (sustantivos, verbos, etc.)

Question Answering Responder preguntas basadas en contexto.

- **Ejemplo extractivo:**
- ”Obama fue el presid... nació en Hawái, en la ... ¿Dónde nació Obama?”
- Respuesta: ”Hawái”.

Taxonomía de Tareas: Generación y Transformación

Summarization Resumir texto largo.

- **Ejemplo:** Artículo
- ”Resumen breve”.

Paraphrasing Reformular manteniendo significado.

- **Ejemplo:** ”Hace frío”
- ”La temperatura es baja”.

Dialogue Responder en conversación.

- **Ejemplo:** Usuario: ”¿Cómo estás?”
- Modelo: ”Muy bien, gracias”.

Translation Traducir idiomas.

- **Ejemplo:** ”Hello world”
- ”Hola mundo”.

Tareas: resumen

Upstream Tasks (Pretraining – aprendizaje general)

- **Auto-supervisadas:** MLM, CLM, NSP, SOP, RTD, Span Corruption
- Aprender representaciones y conocimiento general del lenguaje

Continued Pretraining / Domain Adaptation

- **Auto-supervisadas:** sobre corpus especializado.
- Ejemplo: GPT -> Generamos LegalGPT o MedicalGPT

Downstream Tasks (Fine-tuning o uso contextual)

- **Supervisadas:** Text / Token Classification, QA, Summarization, Paraphrasing, Dialogue, Translation
- **Sin actualización de pesos:** In-context Learning (zero-shot, few-shot)

Estrategias híbridas:

- RAG (Retrieval-Augmented Generation)

Tareas: resumen

Analogía educativa
Pensemos en el modelo como una persona que aprende.

Pretraining: la etapa escolar. Aprende a leer, escribir y el uso del lenguaje. No hay tareas concretas, solo comprensión general del lenguaje y del mundo.

Domain adaptation: la universidad. Se especializa en un campo (medicina, derecho, programación) Aprende con textos del dominio, pero sigue sin etiquetas.

Fine-tuning: el trabajo. Aprende una tarea concreta con ejemplos reales. Ya no estudia teoría: aplica lo aprendido para resolver problemas específicos. **Ejemplos:** un médico que aprende a diagnosticar, o un abogado que redacta demandas

Ejemplos

Familia 1: Encoder-only — BERT

BERT: *Bidirectional Encoder Representations from Transformers*

Características principales

- **Arquitectura:** sólo usa *encoders* del Transformer
- **Bidireccionalidad:** cada token ve todo el contexto (izquierda y derecha)
- **Objetivo de entrenamiento:** *Masked Language Modeling (MLM)* y *Next Sentence Prediction (NSP)*
- Produce **representaciones contextuales** ricas

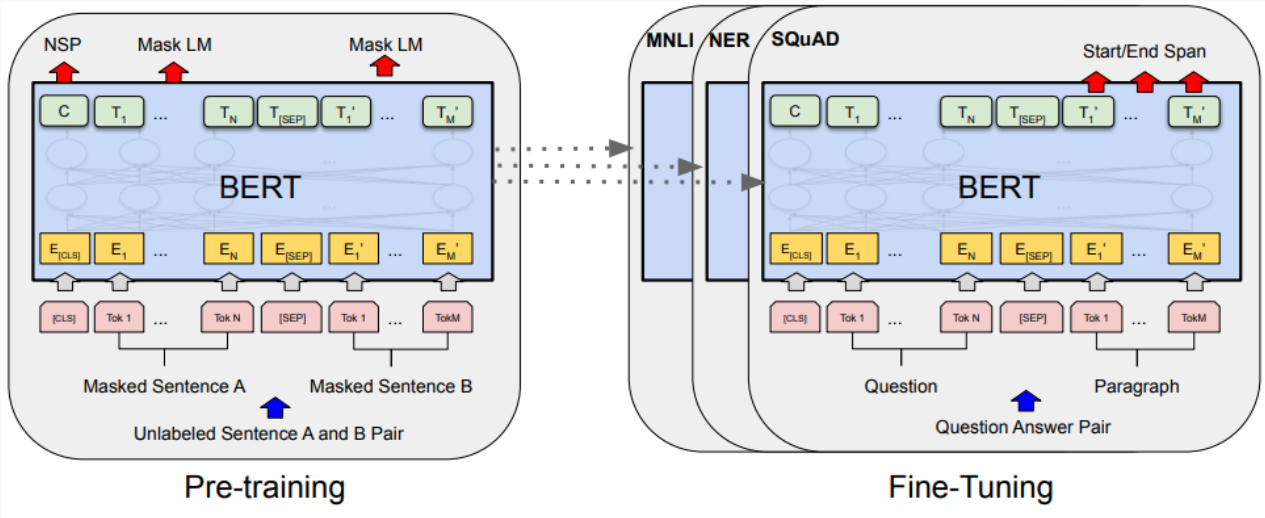

Entrenamiento de BERT (Pre-training)

Objetivo: aprender representaciones lingüísticas generales a partir de grandes corpus sin supervisión.

Datos de entrenamiento: *BooksCorpus* y *Wikipedia* en inglés

Tareas de pre-entrenamiento

- Ambas cabezas (MLM y NSP) se entrenan en paralelo
  $L = L_{\text{MLM}} + L_{\text{NSP}}$
- **Masked Language Modeling (MLM)**
  - Se selecciona aleatoriamente el **15% de los tokens** para intentar predecirlos.
  - De esos tokens seleccionados:
    - 80% se reemplazan por *[MASK]*
    - 10% se reemplazan por un token aleatorio
    - 10% se dejan sin modificar
- **Next Sentence Prediction (NSP)**
  - 50% de los pares son oraciones consecutivas (*IsNext*)
  - 50% son oraciones no relacionadas (*NotNext*)

Representaciones y entrenamiento de BERT

El token [CLS] Se añade al inicio de la secuencia

- Su vector final **resume el significado global** del texto.
- Se usa para tareas de clasificación (*NSP*, análisis de sentimiento, etc.).

Embeddings por token

- Cada token obtiene una representación contextual completa.
- Útiles para tareas de secuencia (NER, QA, POS tagging).

Ejemplo

```
Input: "El [MASK] duerme. Está [MASK]."
 Objetivo MLM: predecir "gato", "cansado"
 Objetivo NSP: IsNext

Input: "El [MASK] duerme. Los trenes son [MASK]."
 Objetivo MLM: predecir "gato", "rápidos"
 Objetivo NSP: NotNext
```

Familia 2: Decoder-only — GPT-2

GPT-2: *Generative Pre-trained Transformer 2*

Características principales

- Usa solo la parte **decoder** del Transformer.
- Entrenamiento **autoregresivo**: predice el siguiente token dado el contexto previo.
- Objetivo de entrenamiento: **Causal Language Modeling (CLM)**.
- Atención **unidireccional**: cada token solo ve los anteriores.

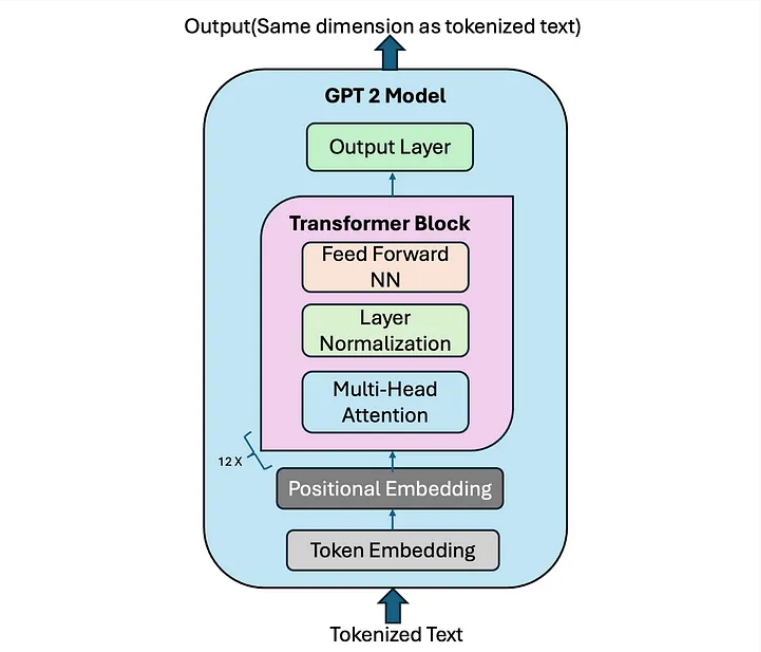

Link a fuente de imagen Masked MHA

GPT-2: *¡Ojo! se entrena en paralelo. En inferencia se va token a token.*

Generación con GPT-2

Objetivo: generar texto coherente y fluido, un token a la vez.

Durante la generación

- El modelo calcula la probabilidad de cada token posible:

$$P(x_t|x_{<t})$$

- Se elige el siguiente token según una estrategia de muestreo.
- El proceso continúa hasta alcanzar un token de parada o el límite de longitud.

Estrategias de muestreo

- **Greedy**: elige siempre el token más probable (poco creativo).
- **Sampling**: elige aleatoriamente según la distribución de probabilidad.
- **Top-k / Nucleus (Top-p)**: limita el muestreo a los tokens más probables.

Generación con GPT-2

Ejemplo de generación

Input: "El gato duerme en" $\rightarrow$ *"el sofá."*

Input: "La IA transformará" $\rightarrow$ *"la educación en el futuro."*

Temperatura y creatividad

Controla la aleatoriedad en el muestreo:

$$P_i' = \frac{\exp(\log P_i / T)}{\sum_j \exp(\log P_j / T)}$$

Temperatura baja ($T < 1$) → texto predecible

Temperatura alta ($T > 1$) → texto más variado

Casos de uso:

- Traducción automática
- Resumen de textos
- Paráfrasis
- Question Answering generativo

Familia 3: Encoder–Decoder - T5

T5: *Text-To-Text Transfer Transformer*

Características principales:

- **Arquitectura completa**: encoder bidireccional + decoder autoregresivo.
- Entrenamiento basado en **denoising**: el modelo aprende a reconstruir texto corrupto.
- Formulación unificada: todo se expresa como una tarea **text-to-text**.
- Máxima **flexibilidad** para tareas de tipo seq2seq.

Familia 3: Encoder–Decoder - T5

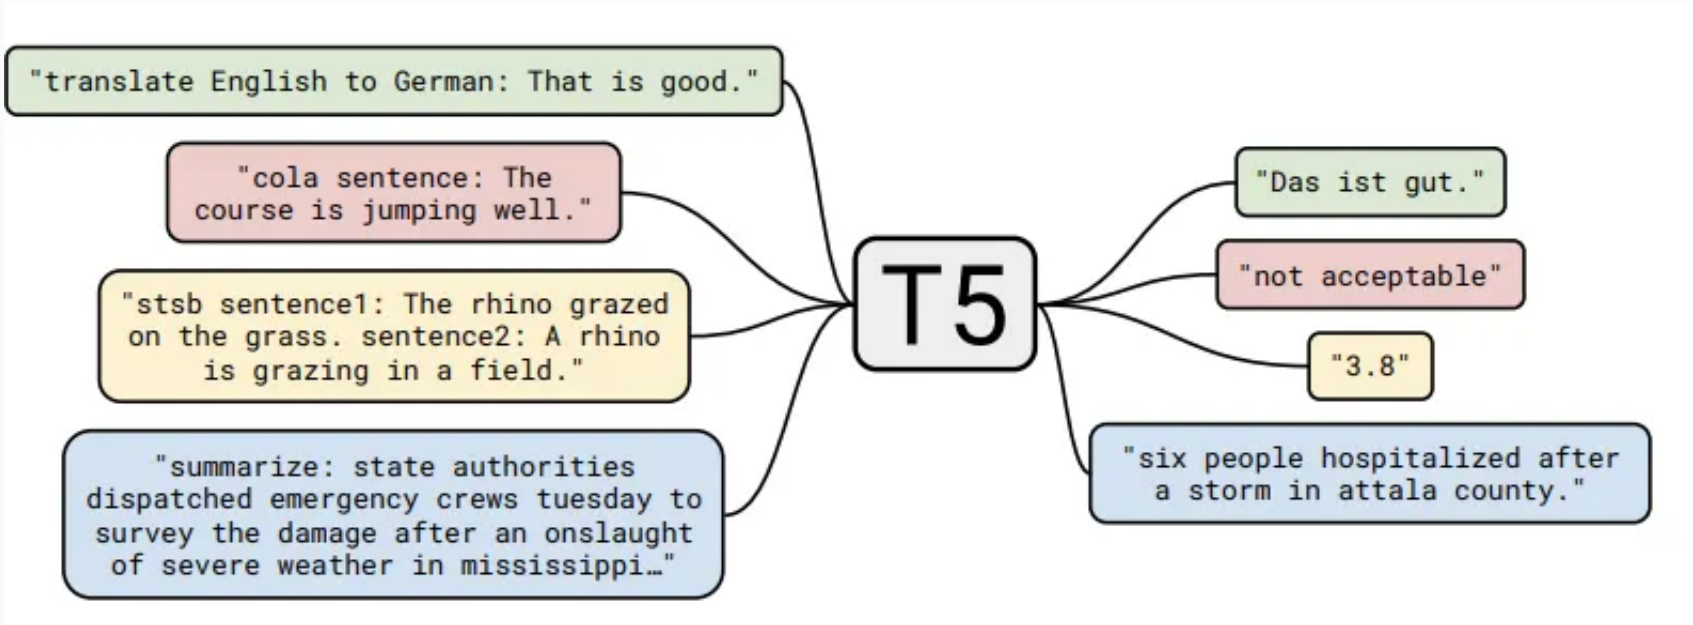

Casos de uso:

- Traducción automática
- Resumen de textos
- Paráfrasis y reformulación
- Question Answering generativo

Comparación de las tres familias

Familia	Atención	Objetivo	Uso principal
Encoder-only	Bidireccional	MLM	Comprensión
Decoder-only	Causal	CLM	Generación
Encoder-decoder	Ambas	Seq2seq	Transformación

Regla general

- ¿Necesitas **entender**? → Encoder-only
- ¿Necesitas **generar**? → Decoder-only
- ¿Necesitas **transformar**? → Encoder-decoder

Por organizar

Ejemplos Concretos del Pipeline

Modelo	Pretraining	Domain Adapt.	Fine-tuning
BERT	Wikipedia + BookCorpus (MLM + NSP)	-	Sentiment classification
BioBERT	Igual que BERT	PubMed + PMC (MLM)	Biomedical NER
GPT-3	Common Crawl + libros (CLM)	-	Few-shot (sin fine-tune)
LegalBERT	Igual que BERT	Legal texts (MLM)	Contract classification

Nota sobre GPT-3

Los modelos muy grandes pueden hacer muchas tareas sin fine-tuning explícito (in-context learning), pero el concepto de fases sigue aplicando a su entrenamiento inicial.

Guía de Decisión: ¿Qué Necesitas Entrenar?

¿Tienes un modelo preentrenado de propósito general?
SÍ → Evalúa si hacer domain adaptation o ir directo a fine-tuning

¿Cuándo hacer DOMAIN ADAPTATION?

- Tu dominio tiene vocabulario muy específico (médico, legal, técnico)
- Tienes muchos datos de dominio sin etiquetar (> 1M documentos)
- El modelo general falla en conceptos básicos de tu dominio
- Vas a hacer múltiples tareas en ese dominio

¿Cuándo ir directo a FINE-TUNING?

- Tu dominio es cercano al lenguaje general
- Tienes pocos datos de dominio
- Solo vas a hacer una tarea específica
- El modelo general ya funciona razonablemente bien

Conceptos Clave del Ecosistema

Paradigmas de Aprendizaje

1. Transfer Learning: Pretraining + Fine-tuning

- Entrenamiento en dos fases
- Modifica los parámetros del modelo
- Requiere dataset de la tarea objetivo
- Ejemplo: BERT pre-entrenado → fine-tuned para clasificación de sentimiento

2. In-Context Learning (emergente en modelos grandes)

- **No modifica** los parámetros del modelo
- Aprende de los ejemplos en el prompt
- Ventana grande, conocimiento amplio
- Solo disponible en modelos suficientemente grandes

In-Context Learning: Zero-shot y Few-shot

Zero-shot: Sin ejemplos

```
Classify the sentiment of this text: "I love this product!"

Answer: Positive
```

Few-shot: Con pocos ejemplos (2-5 típicamente)

```
Classify sentiment:

Text: "Great service!" → Positive

Text: "Terrible experience." → Negative

Text: "I love this!" → ?
```

Diferencia clave
In-context learning NO actualiza parámetros, solo usa el contexto del prompt.

Prompt Engineering

- **Disciplina** que surgió con el auge de los LLMs
- Técnicas principales:
  - **Instruction prompting**: instrucciones claras y específicas
  - **Few-shot prompting**: proporcionar ejemplos
  - **Chain-of-thought**: pedir razonamiento paso a paso
  - **Role prompting**: asignar un rol al modelo
- Arte y ciencia de diseñar instrucciones efectivas
  - CoT -> Modelos razonadores
- El prompt adecuado puede marcar la diferencia entre éxito y fracaso

Chain of Thought (CoT) y Modelos razonadores

Chain of Thought: Pedir al modelo que piense y haga explícito el razonamiento intermedio de una respuesta/tarea.

- **Resultado:** En lugar de dar directamente la respuesta final, el modelo genera una secuencia de pasos lógicos antes de llegar a la solución.
- **Ejemplo:** Para resolver un problema matemático, el modelo escribe los cálculos y justificaciones antes de dar el resultado.
- **Objetivo:** Mejorar la precisión en tareas complejas (matemáticas, lógica, planificación) al permitir que el modelo "razone" de forma estructurada.

Modelos razonadores: Modelos diseñados y optimizados específicamente para razonar de forma más profunda y fiable. **Técnicas empleadas:**

- **Entrenamiento con CoT:** aprenden a generar pasos intermedios.
- **Self-Consistency:** generan varias cadenas de razonamiento y eligen la más coherente.
- **Verificación interna:** el modelo revisa sus propios pasos antes de responder.

Herramientas

Hugging Face Hub: El GitHub de los modelos

¿Qué es Hugging Face Hub?

- Plataforma centralizada para compartir:
  - Modelos pre-entrenados (180,000+)
  - Datasets
  - Spaces (demos interactivas)
- **Model cards**: documentación estandarizada
  - Arquitectura y tamaño
  - Dataset de entrenamiento
  - Métricas de rendimiento
  - Limitaciones conocidas
  - Consideraciones éticas

Biblioteca transformers

- Abstracción unificada
- Mismo código para todos los modelos
- API simple:

```
from transformers import pipeline

classifier = pipeline("sentiment-analysis")

result = classifier("I love this!")
```

Ollama: LLMs Localmente

¿Qué es Ollama?

- Herramienta para ejecutar LLMs en tu máquina
- Interfaz simple tipo Docker
- Optimizado para inferencia local
- Modelos disponibles: LLaMA, Mistral, Phi, etc.

Ventajas:

- Privacidad (datos no salen de tu máquina)
- Sin costes de API
- Control completo

Uso básico

```
$ ollama run llama2

>>> Write a poem

[respuesta del modelo]
```

Requisitos:

- GPU recomendada
- Suficiente RAM/VRAM
- Modelos de 7B+ requieren ≥16GB

LangChain: Orquestando el Razonamiento de los LLMs

¿Qué es LangChain?

- Framework para construir aplicaciones que usan LLMs de forma estructurada.
- Permite conectar modelos con:
  - Fuentes de datos externas (APIs, bases de datos, documentos)
  - Memoria y contexto persistente
  - Herramientas externas (búsquedas, cálculos, acciones)

Componentes principales:

- **Prompt Templates**: diseño sistemático de prompts.
- **Chains**: secuencias de llamadas a modelos o funciones.
- **Agents**: modelos con capacidad de decidir qué acción tomar.
- **Memory**: almacenamiento del contexto de conversación.

Ejemplo básico

Objetivo: Pasar de simples respuestas de texto a flujos de

Consideraciones Prácticas

1. Escalabilidad

- **Distribución**: entrenamiento multi-GPU, multi-nodo
- **Mixture of Experts (MoE)**: activar solo partes del modelo
- **Paralelismo**: de datos, de modelo, de pipeline

2. Trade-offs importantes

- **Tamaño vs. Rendimiento**: modelos más grandes ≠ siempre mejor
- **Calidad vs. Coste**: GPT-4 es mejor pero más caro que GPT-3.5
- **Latencia vs. Throughput**: batch size afecta ambos
- **Precisión vs. Memoria**: FP32 vs FP16 vs INT8

Regla de oro
Empieza con modelos pequeños, escala solo si es necesario.

Técnicas de Optimización

Reducción de tamaño

- **Quantization**: FP16, INT8, INT4
- **Pruning**: eliminar pesos poco importantes
- **Distillation**: entrenar modelo pequeño que imita uno grande
- Ejemplo: DistilBERT (40% más pequeño, 60% más rápido)

Optimización de inferencia

- **KV-cache**: cachear atención en generación
- **Batching**: procesar múltiples inputs juntos
- **Model compilation**: TensorRT, ONNX
- **Speculative decoding**: generar múltiples tokens a la vez

Impacto

Con cuantización a INT8: 4x menos memoria, 2-4x más rápido, pérdida mínima de calidad.

Limitaciones y Retos

Problemas Técnicos

1. Coste Computacional y Memoria

- GPT-3 (175B parámetros): $4.6M en cloud compute
- Inference: modelos grandes requieren múltiples GPUs
- Soluciones: quantization, distillation, MoE

2. Hallucinations (Alucinaciones)

- Generación de información **falsa pero plausible**
- Especialmente problemático en datos fuera de distribución
- Mitigaciones: RAG (Retrieval-Augmented Generation), fine-tuning, prompt engineering

3. Catastrophic Forgetting

- Al fine-tunear, el modelo puede ”olvidar” conocimiento previo
- Soluciones: regularización, continual learning, adapter layers

Problemas Éticos y Sociales

1. Bias en Datos de Entrenamiento

- Los modelos aprenden (y amplifican) sesgos de los datos
- Ejemplos: género, raza, religión, nacionalidad
- Importante: evaluar bias antes de deployment

2. Consideraciones de Uso Responsable

- **Transparencia**: documentar limitaciones (model cards)
- **Privacidad**: datos de entrenamiento pueden memorizar información sensible
- **Dual use**: potencial para desinformación, spam, phishing
- **Impacto ambiental**: huella de carbono del entrenamiento

Responsabilidad
Como desarrolladores, tenemos la responsabilidad de usar estas tecnologías de forma ética.

Futuro y Tendencias

Tendencias actuales (2024-2025):

- **Modelos más eficientes**: Mistral, Phi, Gemma (pequeños pero capaces)
- **Multimodalidad**: GPT-4V, LLaVA (texto + imágenes)
- **Long context**: modelos con contexto de 100K+ tokens
- **Agents**: LLMs que pueden usar herramientas y planificar
- **Open source**: democratización (LLaMA, Falcon, Mistral)

Retos abiertos:

- Razonamiento complejo y matemático
- Consistencia factual
- Personalización eficiente
- Sostenibilidad

Práctica: Explorando el Ecosistema de Transformers

En este notebook exploraremos:

- Las tres familias de transformers (encoder-only, decoder-only, encoder-decoder)
- In-context learning: zero-shot vs few-shot
- Hugging Face Hub: buscar y usar modelos
- Comparar diferentes modelos y tareas

Recursos

- Hugging Face Hub: *https://huggingface.co/models*
- Transformers Documentation: *https://huggingface.co/docs/transformers*
- Ollama: *https://ollama.ai/*
- The Illustrated Transformer: *http://jalammar.github.io/illustrated-transformer/*
- Prompt Engineering Guide: *https://www.promptingguide.ai/*