Redes convolucionales II

Métodos Generativos, curso 2025-2026

Guillermo Iglesias, guillermo.iglesias@upm.es
Jorge Dueñas Lerín, jorge.duenas.lerin@upm.es
Edgar Talavera Muñoz, e.talavera@upm.es

7 de octubre de 2025

Escuela Técnica Superior de Ingeniería de Sistemas Informáticos | UPM

Construcción de una CNN

La estructura de embudo típica de las redes neuronales clasificadoras también se aplica a Convolutional Neural Network (CNN). Para ello el objetivo es reducir la dimensión de la imagen hasta generar una salida.

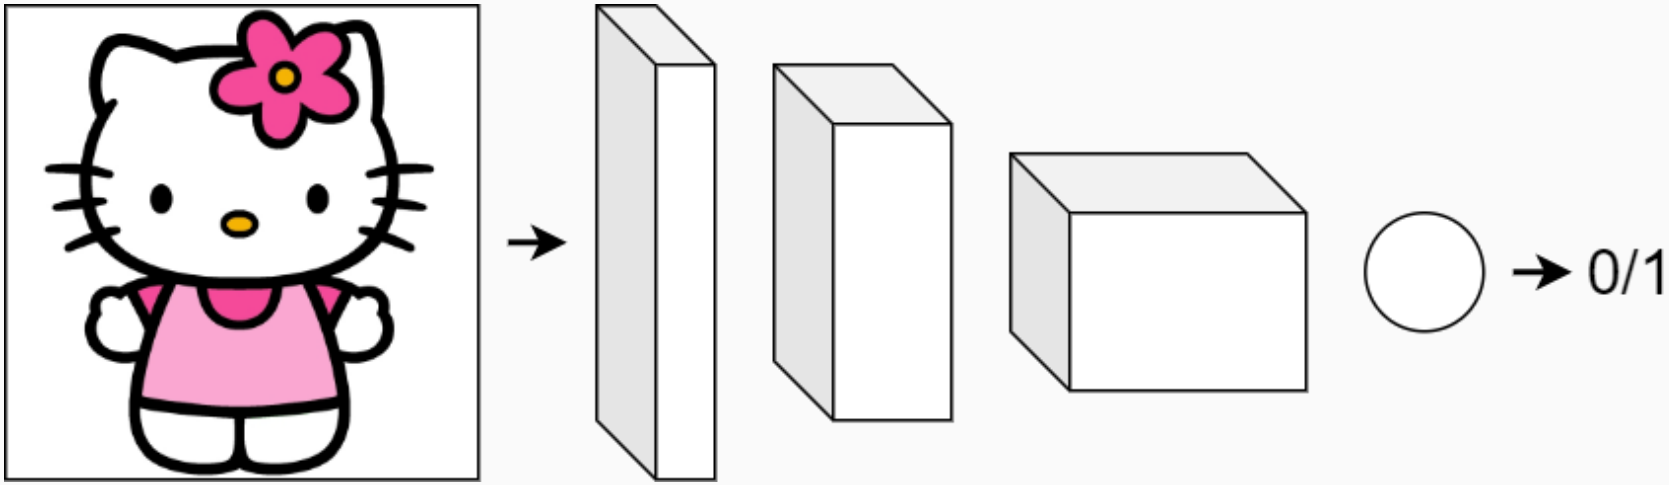

Construcción de una CNN

Las primeras capas convolucionales de la red se encargan de la extracción de características de la imagen. Posteriormente un perceptrón se encarga de clasificar las características extraídas para generar la salida deseada.

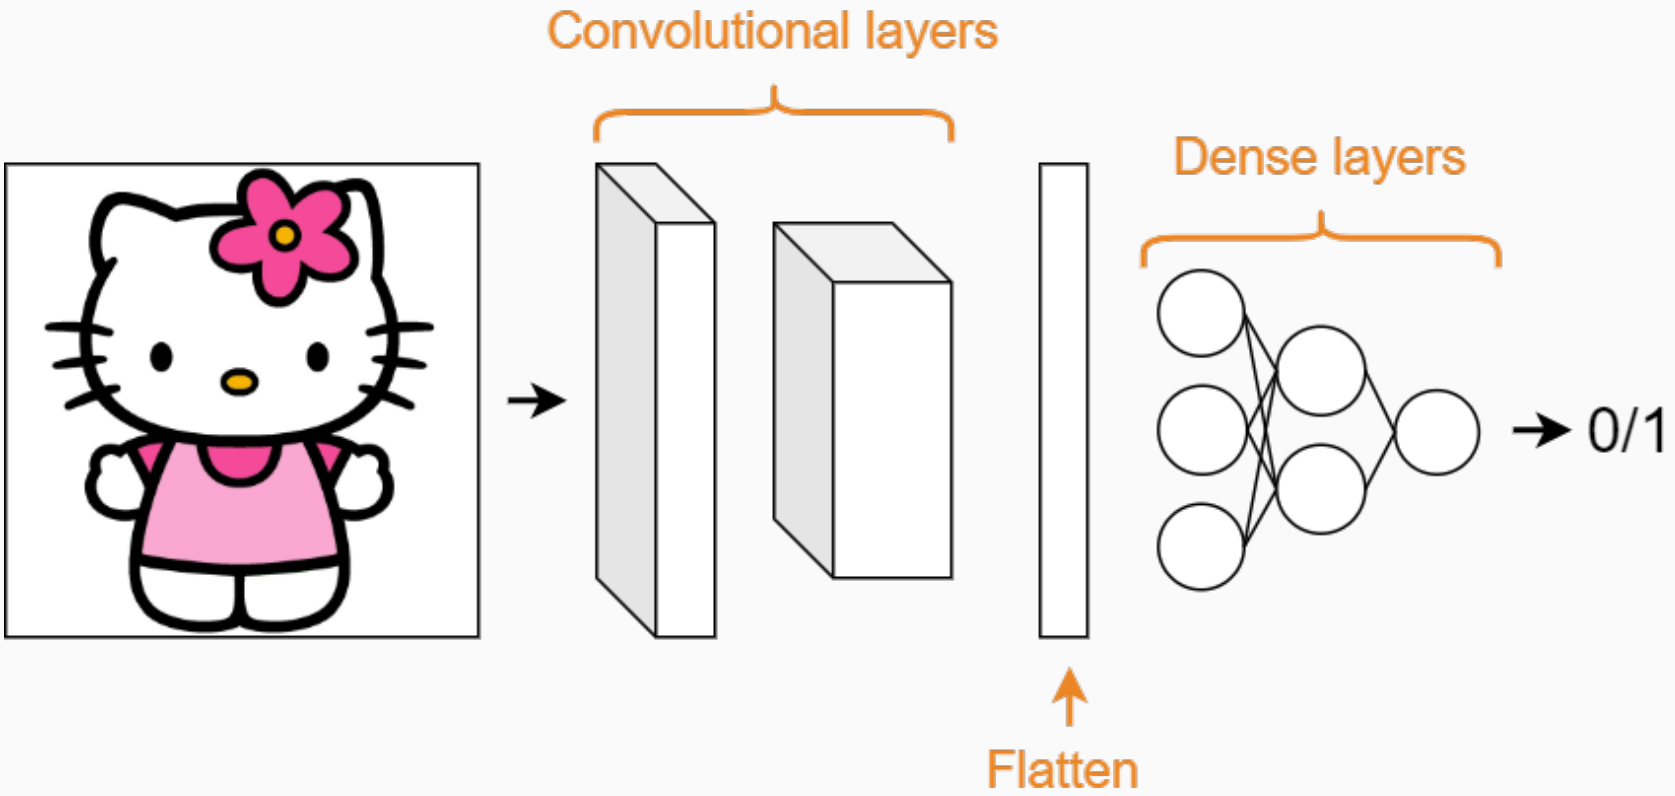

Construcción de una CNN

Es importante recordar que la jerarquía de capas de una red convolucional detecta características a alto nivel en las capas más profundas.

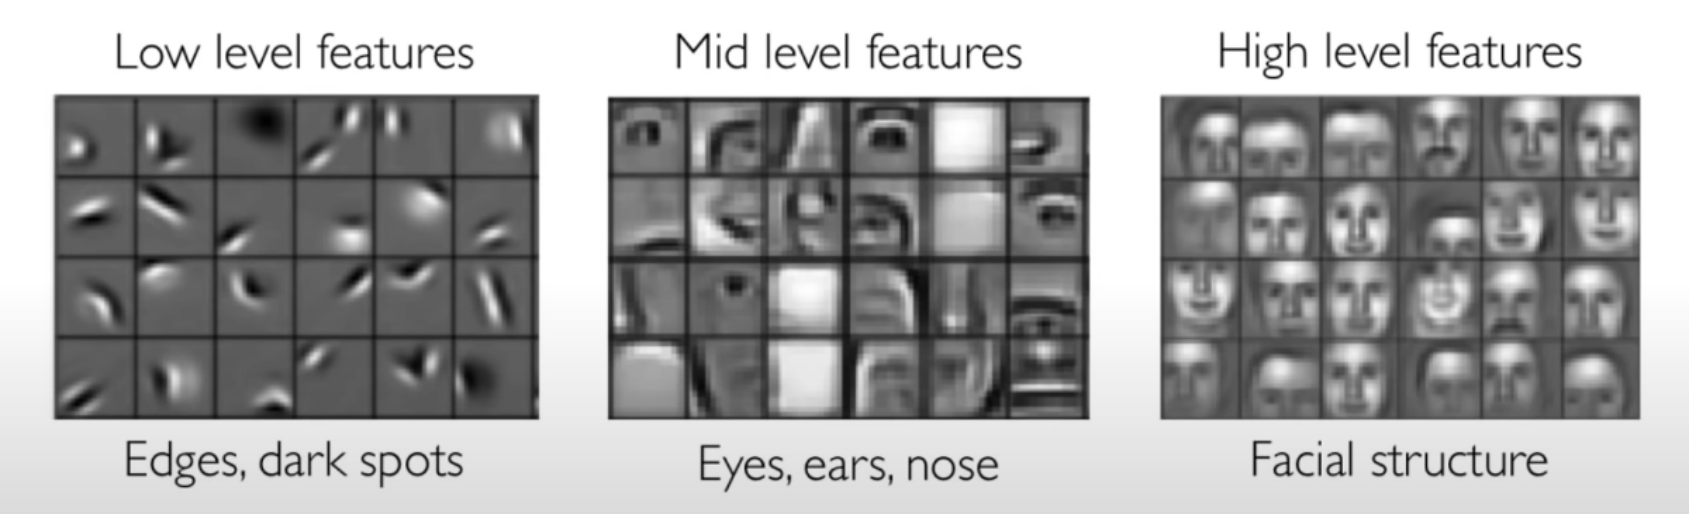

[1]

Reducción dimensional en redes convolucionales

Para formar el “embudo” de la red se utilizan distintos mecanismos para reducir las dimensiones de la información de la red. En concreto los dos mecanismos predominantes son:

- Capas de pooling
  - MaxPooling
  - AveragePooling
- Convoluciones de strides=(2,2)

Reducción dimensional con Pooling

MaxPooling 2D La capa de MaxPooling2D reduce la dimensión de un vector cogiendo el máximo de la ventana definida.

pool_size = (2, 2)

1	2	0	2
1	4	2	0
4	3	1	0
1	2	2	1

Reducción dimensional con Pooling

MaxPooling 2D La capa de MaxPooling2D reduce la dimensión de un vector cogiendo el máximo de la ventana definida.

pool_size = (2, 2)

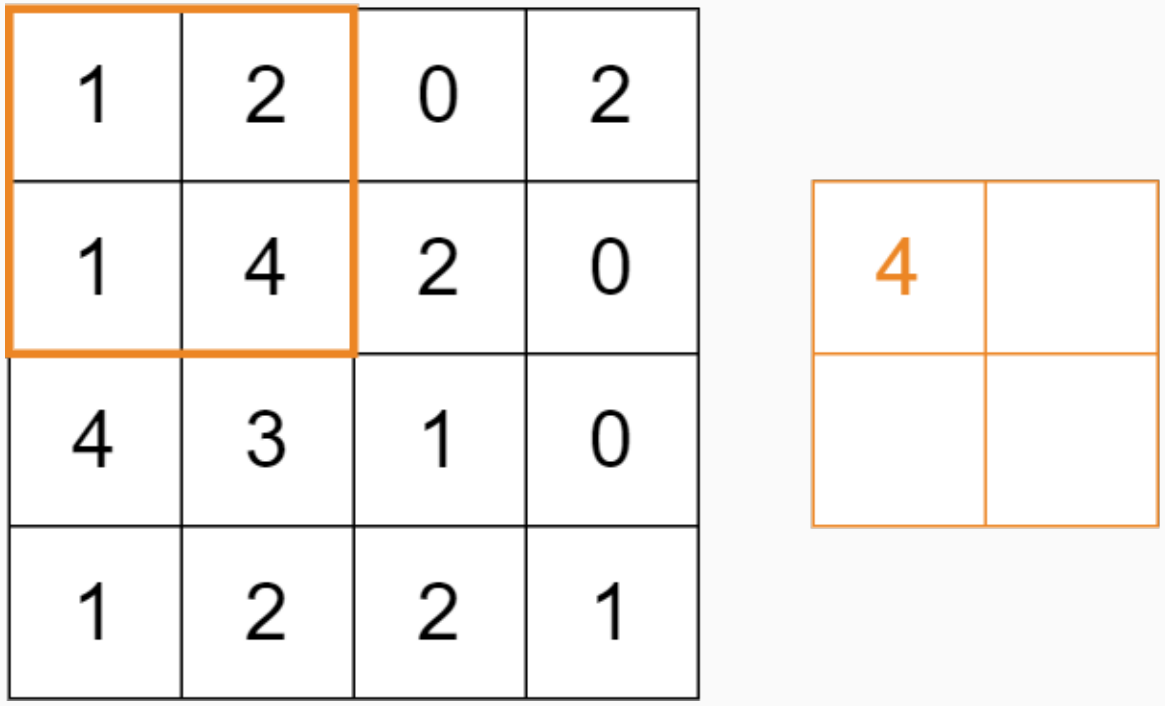

Reducción dimensional con Pooling

MaxPooling 2D La capa de MaxPooling2D reduce la dimensión de un vector cogiendo el máximo de la ventana definida.

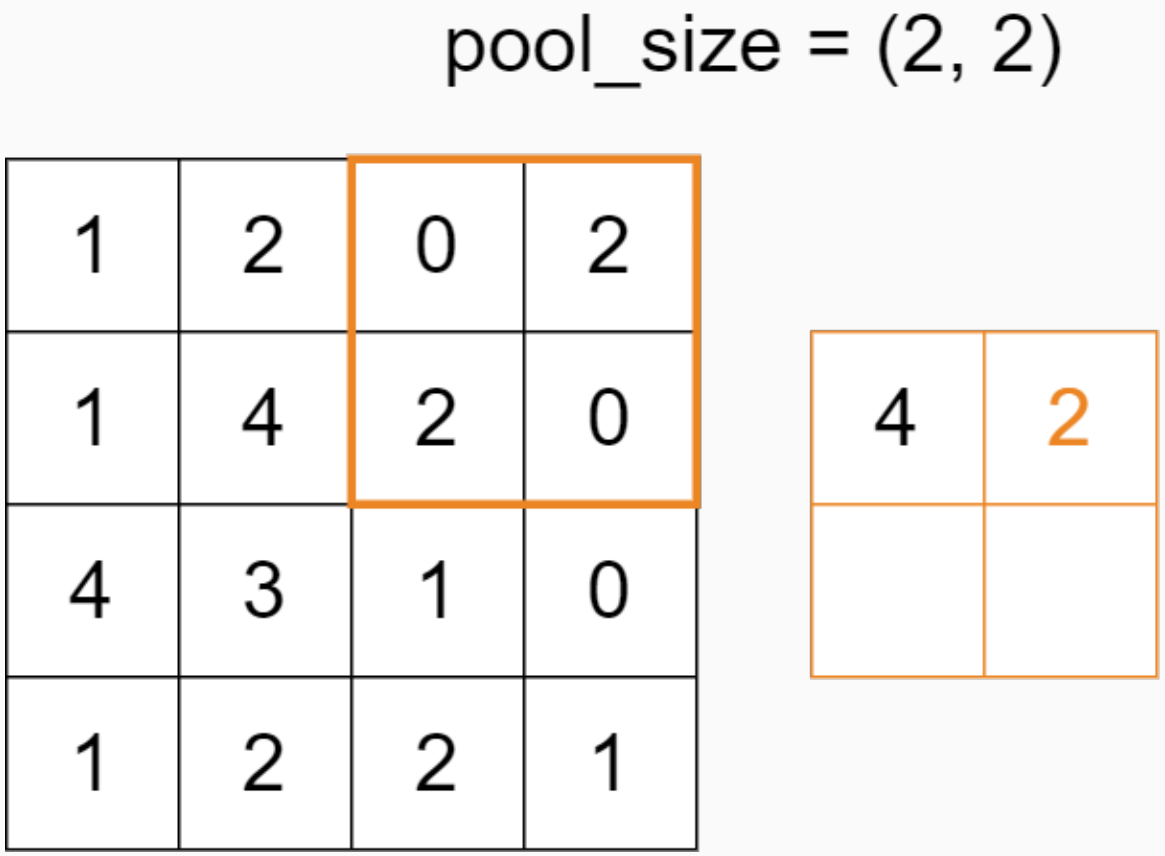

Reducción dimensional con Pooling

MaxPooling 2D La capa de MaxPooling2D reduce la dimensión de un vector cogiendo el máximo de la ventana definida.

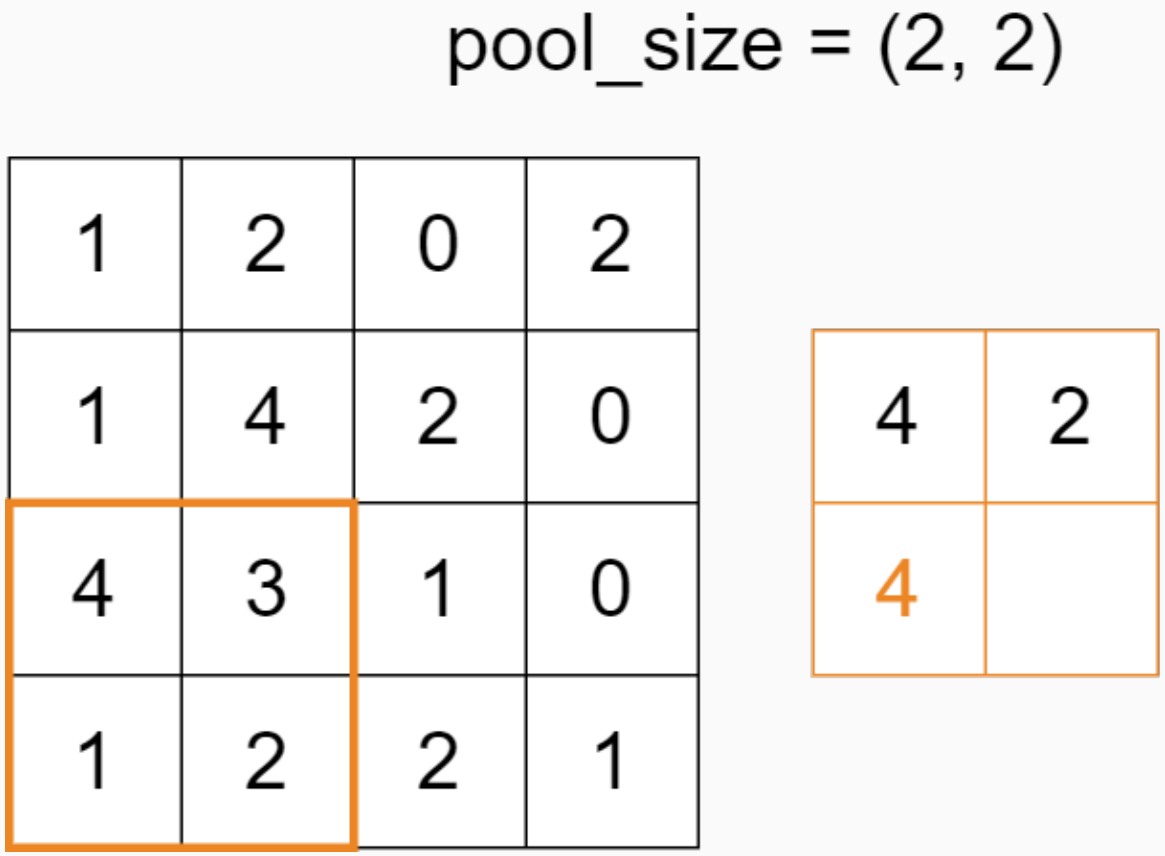

Reducción dimensional con Pooling

MaxPooling 2D La capa de MaxPooling2D reduce la dimensión de un vector cogiendo el máximo de la ventana definida.

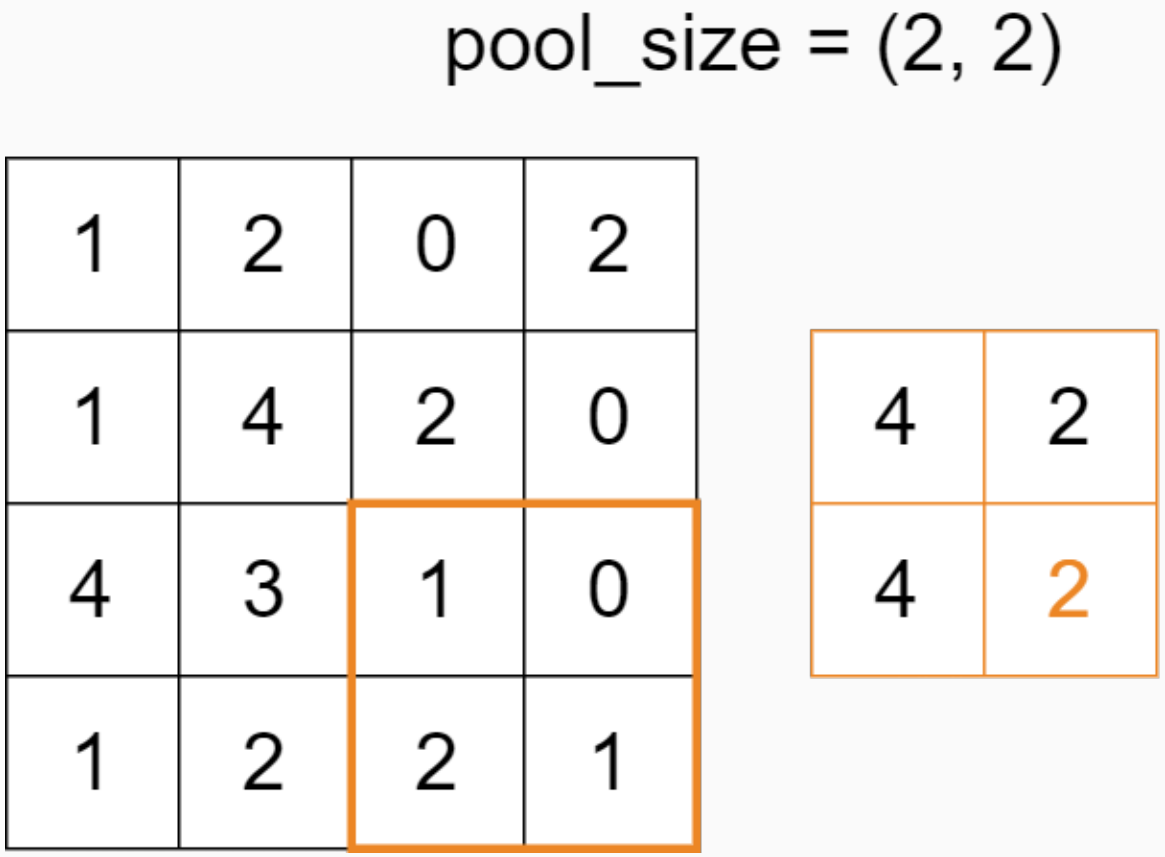

Reducción dimensional con Pooling

MaxPooling 2D La capa de MaxPooling2D reduce la dimensión de un vector cogiendo el máximo de la ventana definida.

pool_size = (2, 2)

1	2	0	2
1	4	2	0
4	3	1	0
1	2	2	1

4	2
4	2

**cabe destacar que el máximo se encarga de preservar la característica más importante*

Reducción dimensional con Pooling

AveragePooling 2D La capa de AveragePooling2D reduce la dimensión de un vector cogiendo el promedio de la ventana definida.

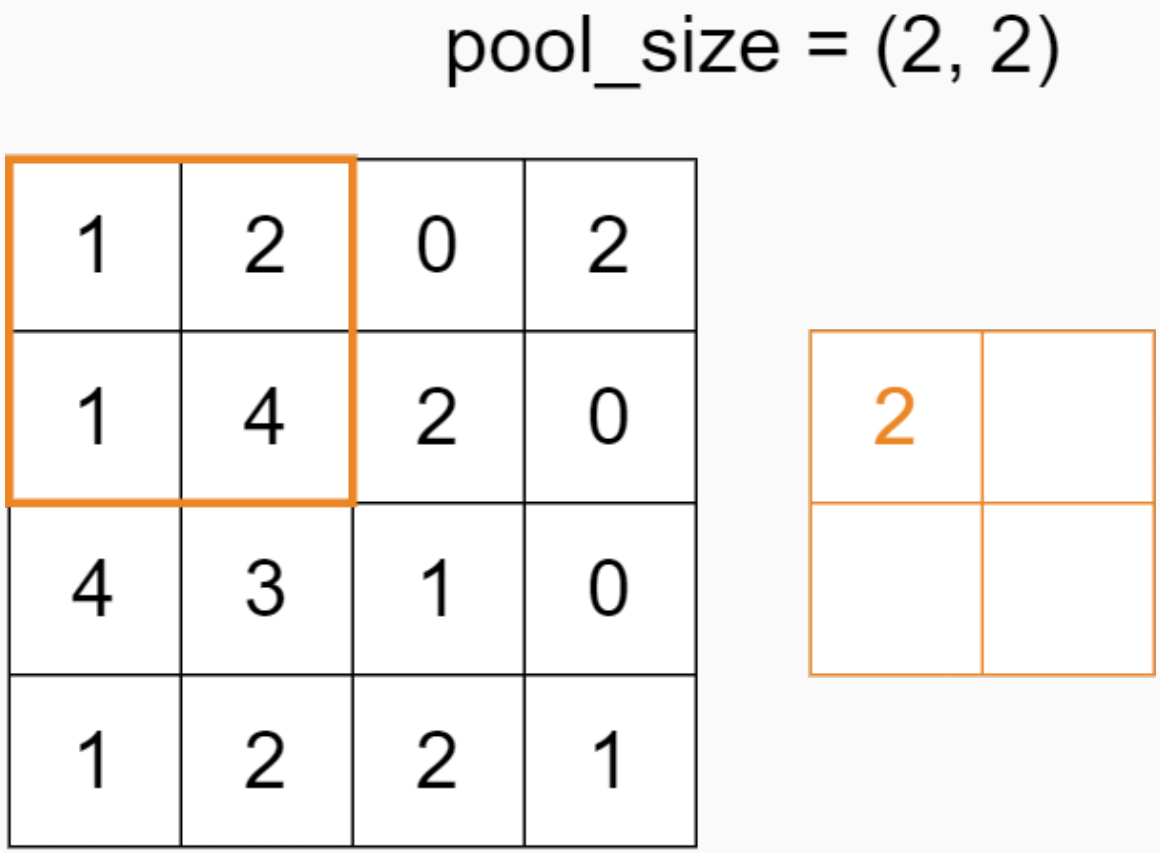

Reducción dimensional con Pooling

AveragePooling 2D La capa de AveragePooling2D reduce la dimensión de un vector cogiendo el promedio de la ventana definida.

pool_size = (2, 2)

1	2	0	2
1	4	2	0
4	3	1	0
1	2	2	1

2	1

Reducción dimensional con Pooling

AveragePooling 2D La capa de AveragePooling2D reduce la dimensión de un vector cogiendo el promedio de la ventana definida[1].

pool_size = (2, 2)

1	2	0	2
1	4	2	0
4	3	1	0
1	2	2	1

2	1
2.5	1

[1] Pese a su similitar rendimiento, el MaxPooling suele generar mejores resultados que el AveragePooling [2]

Reducción dimensional con strides

Otra opción para la reducción dimensional es el uso de convoluciones con strides que no sean (1, 1).

- Cierta literatura apunta a esta aproximación como "más inteligente" ya que se le permite a la red que sea ella la que escoja cómo hacer la reducción.
- El principal inconveniente es que usando este método se aumenta el número de parámetros de la red.

Existe un debate abierto sobre si es preferible que la red aprenda a realizar el *downsampling* [3], o si resulta más adecuado emplear técnicas como MaxPooling [4].

**Normalmente el stride elegido es de (2, 2) pero hay libertad para adaptarlo a distintos casos.*

Capa de dropout

La capa de dropout es una capa de regularización que desactiva aleatoriamente la activación de ciertas neuronas durante el entreno.

Al regularizar la red previene de problemas como el overfitting.

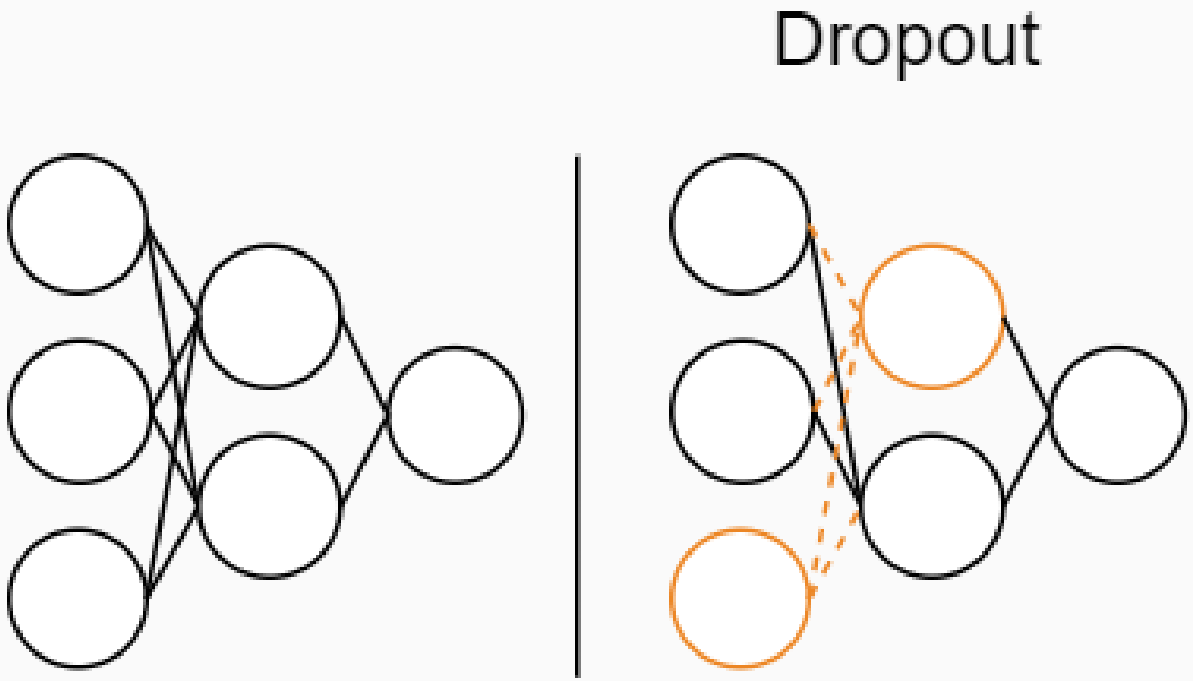

Tuneo de CNNs

Los hiperparámetros en una red

Uno de los mayores inconvenientes a la hora de realizar entrenamientos con redes neuronales artificiales es su difícil configuración. Debido a la cantidad inmensa de hiperparámetros a escoger.

Sin embargo, existen una serie de prácticas comunes a la hora de tratar con CNNs.

Tamaño de imagen y filtros

A la hora de escoger el número de filtros de cada capa convolucional este va ligado al tamaño de la matriz de datos.

A medida que la imagen de entrada va reduciendo su tamaño, el número de filtros aumenta. Con esto se pretende extraer más características de alto nivel cada vez cubriendo zonas más amplias de la imagen original.

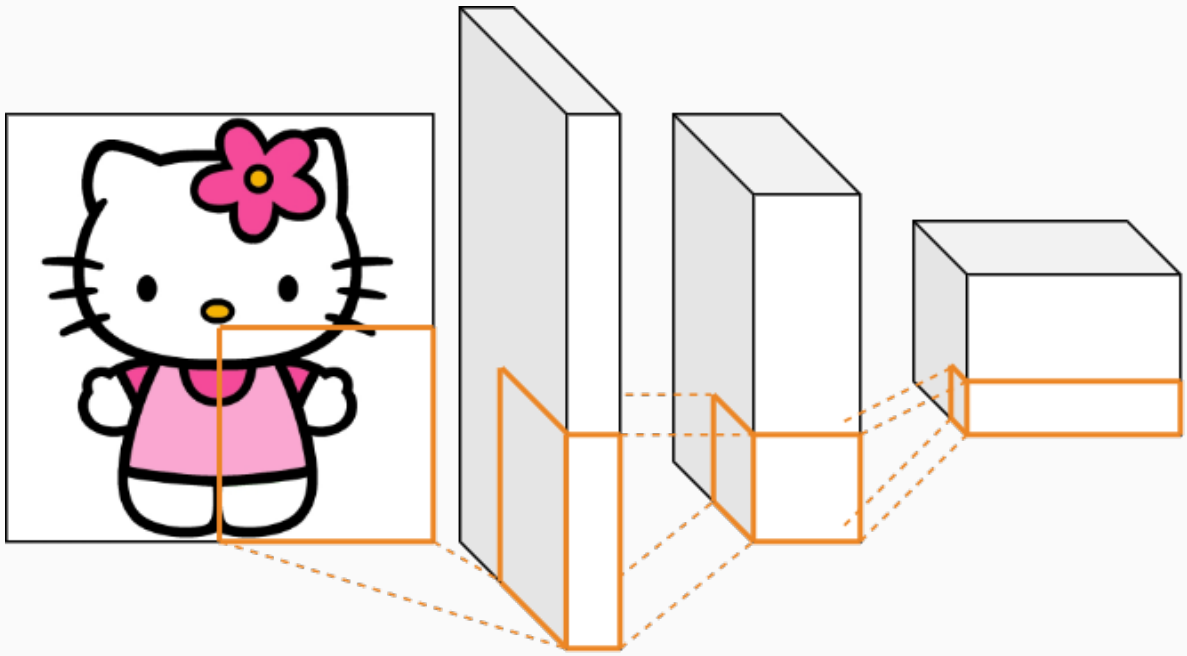

Tamaño de imagen y filtros

Al mismo tiempo, a medida que el número de filtros de multiplica por 2 las dimensiones de la matriz de datos se reducen a la mitad.

El objetivo de este intercambio es mantener la misma cantidad de información, pero tratada por la red.

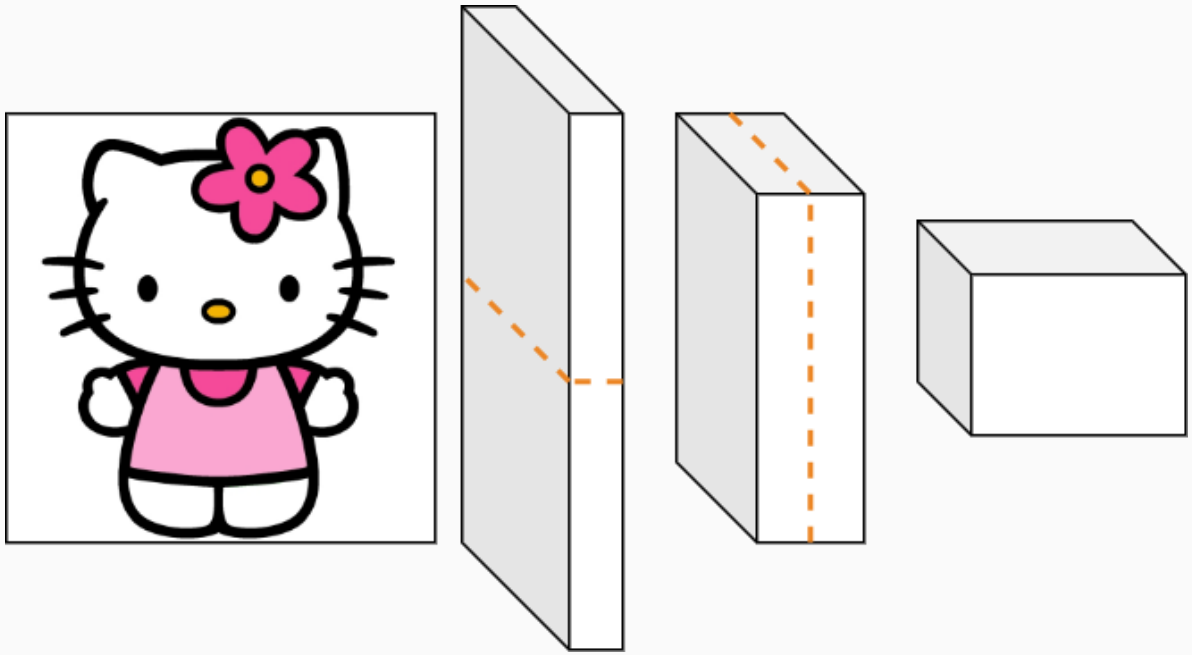

Otros hiperparámetros

kernel_size

El tamaño del kernel habitualmente es de (3, 3) o (5, 5), en caso de imágenes muy grandes puede llegar a (7, 7).

Para matrices de datos más grandes se utilizan kernels más grandes, en casos combinando kernels de (5, 5) para las primeras capas y posteriormente (3, 3) para capas más profundas[2].

strides

El paso de la convolución se mantiene a (1, 1) a no ser que se desee una reducción dimensional.

[2] Investigaciones posteriores [5] han demostrado que es más eficiente apilar dos capas convoluciones de (3, 3) que una única capa de (5, 5).

Otros hiperparámetros

padding

El padding de una convolución suele ser same para controlar las dimensiones de la matriz de datos, pero no es extraño encontrar casos con padding valid.

activation

Para las capas ocultas se suele utilizar la función ReLU o LeakyReLU, para la capa de salida la activación depende del problema concreto.

Ejemplo

- 1.2_3-CNNModa.ipynb

Ejercicio

- 1.2_4-CNNDigitos.ipynb

Idea general

Usar un modelo preentrenado en un dataset grande (ej. ImageNet) para una nueva tarea.

- Enfoques comunes
  - Feature extraction: congelar capas y usar sus salidas como extractor de características.
  - Fine-tuning: reentrenar parcialmente algunas capas junto con las nuevas.
- Ventajas
  - Reduce el tiempo de entrenamiento.
  - Mejora los resultados con pocos datos.
  - Facilita el uso de arquitecturas complejas.

Ejemplo: VGG16

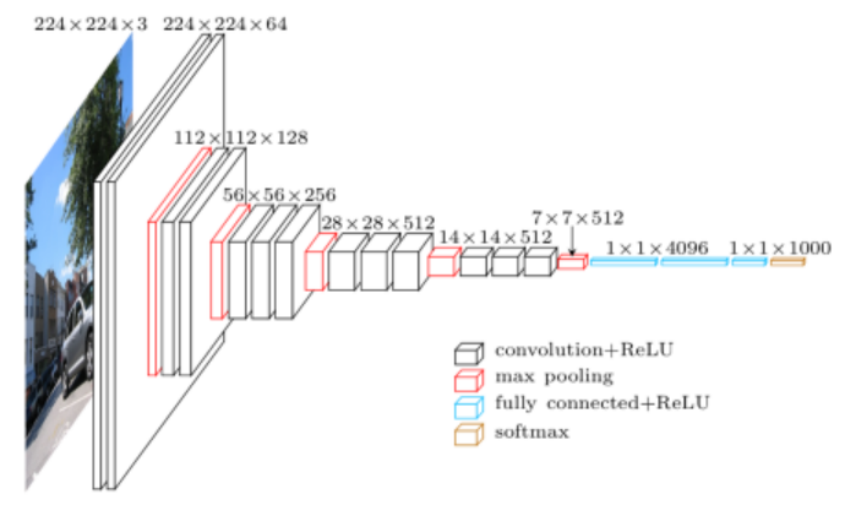

- VGG16
  - Red profunda propuesta por Simonyan y Zisserman (2014). *https://arxiv.org/abs/1409.1556*
  - Basada en bloques de convoluciones en embudo y luego densa.
- Uso en Transfer Learning
  - Importar el modelo preentrenado. Congelar sus pesos.
  - Sustituir densa por nueva densa.
  - Opcionalmente: descangelar algún filtro del final.

Ejemplo/Ejercicio

- 1.2_05-Cuadros.ipynb

Referencias i

[1] Kathrin Melcher (Medium).
Convolutional hierarchy image.
https://medium.com/low-code-for-advanced-data-science/introduction-to-convolutional-neural-networks-and-computer-vision-72b2d85dd1c0.
[Online; accessed August, 2022].

[2] Florentin Bieder, Robin Sandkühler, and Philippe C Cattin.
Comparison of methods generalizing max-and average-pooling.
arXiv preprint arXiv:2103.01746, 2021.

[3] itdxer (StackExchange).
Strides vs maxpooling debate.
https://stats.stackexchange.com/questions/387482/pooling-vs-stride-for-downsampling.
[Online; accessed September, 2023].

Referencias ii

[4] Shuyang Sun, Jiangmiao Pang, Jianping Shi, Shuai Yi, and Wanli Ouyang.
Fishnet: A versatile backbone for image, region, and pixel level prediction.
Advances in neural information processing systems, 31, 2018.

[5] Karen Simonyan and Andrew Zisserman.
Very deep convolutional networks for large-scale image recognition.
arXiv preprint arXiv:1409.1556, 2014.

Contribuciones de las diapositivas

- **Autor original de las diapositivas:** Guillermo Iglesias Hernández