

# Introducción a los métodos genetativos

Métodos Generativos, curso 2025-2026

---

Guillermo Iglesias, guillermo.iglesias@upm.es

Jorge Dueñas Lerín, jorge.duenas.lerin@upm.es

Edgar Talavera Muñoz, e.talavera@upm.es

5 de noviembre de 2025

Escuela Técnica Superior de Ingeniería de Sistemas Informáticos | UPM



# Contenidos

1. Introducción
2. Auto-encoders (AEs)
3. Auto-encoders Variacionales (VAEs)
4. Generative Adversarial Networks (GANs)
5. Transformers
6. Diffusion Models

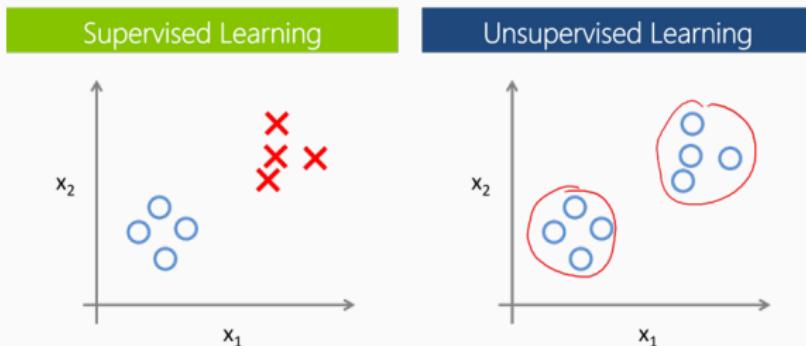
# Introducción a los métodos generativos

---

# Paradigmas de aprendizaje y modelos

Existen distintos paradigmas de aprendizaje y distintos tipos de modelos:

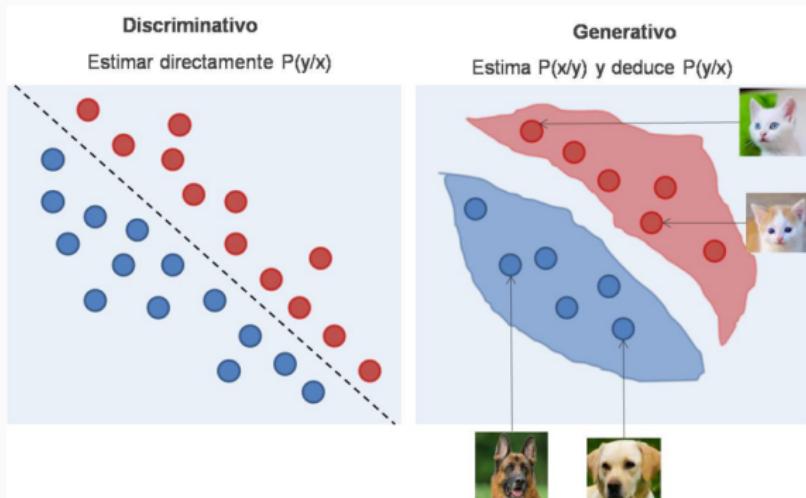
- Aprendizaje supervisado vs. no supervisado



# Paradigmas de aprendizaje y modelos

Existen distintos paradigmas de aprendizaje y distintos tipos de modelos:

- Aprendizaje supervisado vs. no supervisado
- Modelos discriminativos vs. generativos

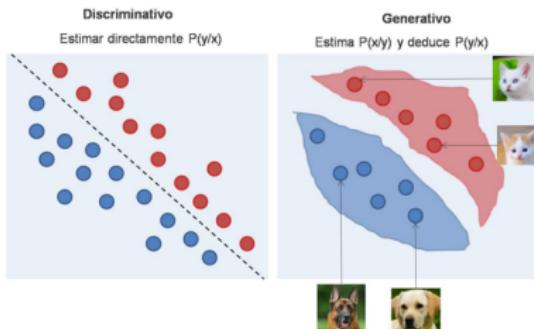


# Paradigmas de aprendizaje y modelos

## Tipos de modelos:

- **Discriminativos:** tratan de encontrar la dependencia entre los datos de entrada y los distintos tipos de clases
- **Generativos:** tratan de encontrar “cómo fueron generados” los datos teniendo en cuenta los distintos tipos de clases existentes

Probabilidad de que sea un perro teniendo una entrada de pixels determinada (probabilístico o mapeo)



Qué distr. de prob. tiene la entrada para la clase perro, y de ahí deduce si los datos podrían haber sido extraídos de esa distr. de prob. o no

## Modelos discriminativos

- Son ampliamente utilizados en aplicaciones del mundo real debido a su eficacia en muchas tareas de aprendizaje supervisado.
- Se centran en aprender directamente la frontera de decisión entre clases o la función que mapea las entradas a las salidas.
- Generalmente son más rápidos en la fase de predicción una vez entrenados.
- Suelen tener un mejor desempeño en tareas de clasificación.
- Interpretabilidad variable: Algunos modelos (como árboles de decisión) son más interpretables, mientras que otros (como redes neuronales profundas) son menos transparentes.

## Ejemplos de modelos discriminativos

- Regresión lineal/logística
- Árboles de decisión
- Support Vector Machines
- Redes neuronales

## Modelos generativos

- Además de aprender a diferenciar, también aprenden la estructura intrínseca de los datos.
- Modelan la distribución de probabilidad conjunta  $P(x,y)$  de las características  $x$  y las etiquetas  $y$ , o la distribución  $P(x)$  de los datos de entrada.
- Son útiles en aprendizaje no supervisado como clustering o reducción de dimensionalidad. También en detección de anomalías.
- Son más costosos computacionalmente.

## Ejemplos de modelos generativos

- Naive Bayes
- Máquinas de Boltzmann (RBM)
- Modelos de Markov (HMM)
- Gaussian Mixture Models (GMMs)
- Autoencoders variacionales (VAEs)
- Generative Adversarial Networks (GANs)
- Transformers
- Diffusion Models

# Modelos generativos tradicionales

Antes de la época del Deep Learning ya existían modelos generativos, tanto basados en redes neuronales, como no basados en ellas.

Estos modelos generativos tradicionales han sido fundamentales en la modelización y generación de datos antes de la era del aprendizaje profundo.

Algunos de estos modelos basados en DL son:

- Restricted Boltzmann Machines (RBMs)
- Hidden Markov Models (HMMs)

En cuanto a los no basados en redes neuronales, destacan los Gaussian Mixture Models (GMMs).

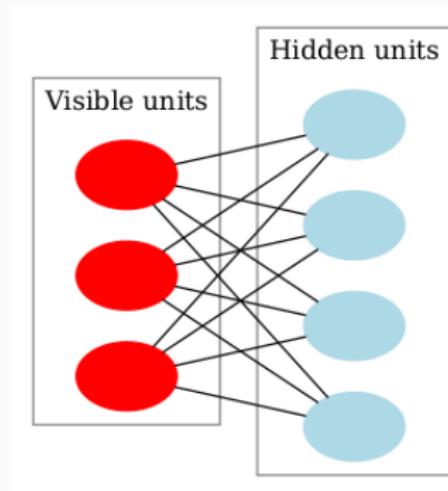
## Naive Bayes:

- Aprende la distribución conjunta de los datos y las etiquetas
- $P(C = \text{spam} | X = \text{"oferta", "urgente"})$
- $P(C | X) = \frac{P(X|C)P(C)}{P(X)}$

# Modelos generativos tradicionales

## Restricted Boltzmann Machine (RBM):

- Red neuronal restringida.
- Modelo de dos capas: capa visible y capa oculta.
- Emplea aprendizaje por divergencia contrastiva para entrenar.



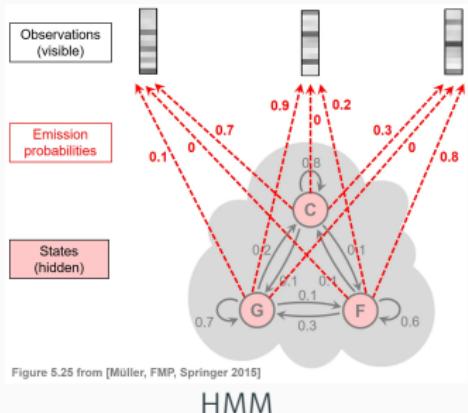
Wikipedia

1. **Paso hacia adelante:** Se ingresan datos a la RBM y la capa oculta se activa con esa información.
2. **Reconstrucción:** A partir de la capa oculta, se intenta reconstruir los datos de entrada en la capa visible.
3. **Comparación y ajuste:** Se compara la reconstrucción con los datos originales y se ajustan los pesos si hay diferencias.
4. El proceso se repite varias veces para que la RBM mejore en la reconstrucción de los datos.

# Modelos generativos tradicionales

## Hidden Markov Model (HMM):

- Modela secuencias de datos como procesos de Markov ocultos.
- Ampliamente utilizado en procesamiento de señales y lenguaje natural.



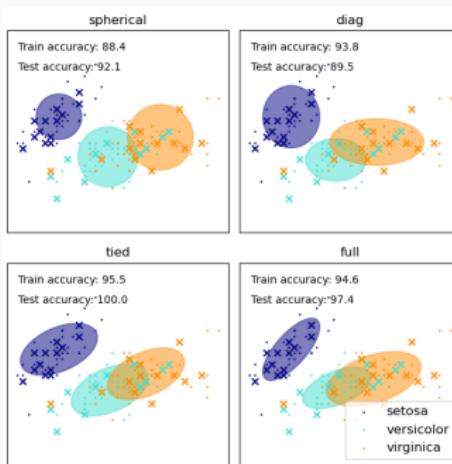
HMM sigue la premisa de que hay un conjunto de estados ocultos (no observables) que evolucionan con el tiempo de acuerdo a un proceso de Markov. Estos estados ocultos emiten las observaciones visibles.

HMM modela la probabilidad conjunta de las observaciones X y los estados ocultos Y a lo largo del tiempo.

# Modelos generativos tradicionales

## Gaussian Mixture Model (GMM):

- Modela datos como mezcla de distribuciones gaussianas.
- Útil para modelar datos con múltiples modos o clusters.
- Emplea la expectativa-maximización (EM) para ajustar los parámetros.
- Se emplea tradicionalmente para *clustering* de datos.



<https://scikit-learn.org/stable/modules/mixture.html>.

# Contenidos

---

1. Introducción
2. Auto-encoders (AEs)
3. Auto-encoders Variacionales (VAEs)
4. Generative Adversarial Networks (GANs)
5. Transformers
6. Diffusion Models

# Recursos

- Diapositivas de Moodle
- Google Collaboratory
- Deep Learning Book (<https://www.deeplearningbook.org/>)
- <https://www.pyimagesearch.com/blog>
- <https://machinelearningmastery.com/blog>